Teoria da Informação – Primeira Atividade em Grupo

Relatório das Simulações

Gabriel Takeuchi (13671636) Gabriela Victor (11795381)
Francisco Membrive (12553782) Octavio Carneiro (13831609)
Fernando Lima (13672710) Pedro Bonifácio (14602244) Ulisses Cordeiro

1 Tópico 1: Entropia, Informação Mútua e Teste de Independência

1.1 Modelo de diagnóstico, convergência e custo de codificação

Definimos o modelo probabilístico do teste rápido de dengue com prevalência $p(D = 1) = 0{,}10$, taxa de falso positivo $p(T = 1 \mid D = 0) = 0{,}05$ e taxa de falso negativo $p(T = 0 \mid D = 1) = 0{,}20$. A partir de uma amostra simulada de $N = 5\,000$ pacientes, construímos a tabela de contingência 2×2 e calculamos as entropias e a informação mútua pelas frequências relativas empíricas. A Tabela 1 mostra que as estimativas ficaram bem próximas dos valores teóricos, preservando exatamente as identidades $H(D \mid T) = H(D, T) - H(T)$ e $I(D;T) = H(D) - H(D \mid T) \approx 0{,}214$ bits.

Tabela 1: Comparação entre valores teóricos e estimados na amostra ($N = 5\,000$).

Quantidade	Teórico	Estimado ($N = 5000$)	Diferença
$H(D)$	0.4690	0.4490	-0.0200
$H(T)$	0.5436	0.5077	-0.0359
$H(D,T)$	0.7989	0.7516	-0.0474
$H(D\|T)$	0.2554	0.2438	-0.0115
$I(D;T)$	0.2136	0.2052	-0.0084

Para analisar o comportamento do estimador em função do tamanho amostral, repetimos a simulação 500 vezes para $N \in \{20, 50, 100, 500, 2\,000, 10\,000\}$, tanto no modelo real quanto em um cenário com D e T independentes ($I = 0$). Como ilustrado na Figura 1, o erro quadrático médio diminui conforme N cresce, mas amostras pequenas sofrem com um viés positivo sistemático: para $N = 20$, obtemos em média $\hat{I} \approx 0{,}248$ bits no modelo dependente e $\hat{I} \approx 0{,}039$ bits sob independência. Esse viés decorre da relação assintótica $2N \ln(2)\, \hat{I} \sim \chi^2_1$, cuja esperança implica $E[\hat{I}] \approx 1/(2N \ln 2) \approx 0{,}036$ bits para $N = 20$.

Avaliamos também o efeito de projetar a codificação assumindo uma distribuição incorreta $q(D = 1) = 0{,}30$. O custo teórico médio passa de $H(p) = 0{,}4690$ para a entropia cruzada $H(p, q) = 0{,}6368$ bits, resultando em um excesso igual à divergência de Kullback-Leibler $D(p\|q) = 0{,}1678$ bits por paciente. Na amostra simulada, a diferença entre os comprimentos médios ideais ($-\log_2 q(d)$ versus $-\log_2 p(d)$) foi de 0,1799 bits, ligeiramente acima do valor teórico devido à flutuação da frequência amostral de infectados (9,4%). Além disso, verificamos a assimetria da divergência, uma vez que $D(q\|p) = 0{,}2217 \neq D(p\|q)$.

1.2 Dependência temporal e teste de independência

Para incorporar a persistência temporal nos resultados de um mesmo paciente ao longo de $n = 8$ dias, simulamos 200 000 históricos a partir de uma cadeia de Markov de dois estados com matriz de transição $P = \left(\begin{smallmatrix} 0{,}9 & 0{,}1 \\ 0{,}2 & 0{,}8 \end{smallmatrix}\right)$, iniciada na distribuição estacionária $\pi = (2/3, 1/3)$. No primeiro dia, a incerteza é $H(T_1) \approx 0{,}918$ bits; a partir do segundo dia, a entropia condicional estabiliza em

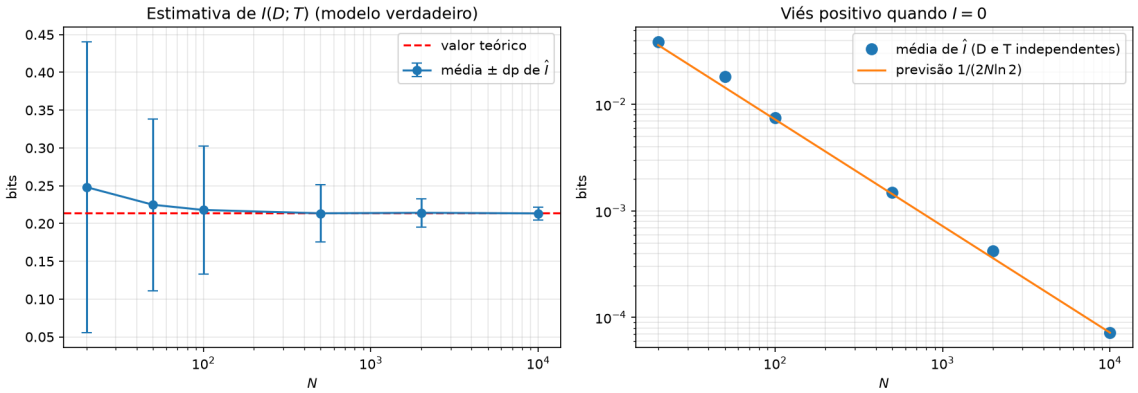


Figura 1: Convergência de $\hat{I}(D;T)$ com o tamanho da amostra (esquerda) e viés positivo sob independência comparado à aproximação teórica $1/(2N\ln 2)$ (direita).

$\hat{H}(T_i \mid T_1,\ldots,T_{i-1}) \approx \hat{H}(T_i \mid T_{i-1}) \approx 0{,}553$ bits, confirmando que dias anteriores a $i-1$ não trazem informação adicional dado o dia imediatamente anterior. Pela regra da cadeia, o histórico completo requer $H(T_1,\ldots,T_8) \approx 4{,}78$ bits, contra $8H(T_1) \approx 7{,}34$ bits da transmissão independente dia a dia. A economia obtida é de 2,56 bits por histórico de 8 dias, valor que coincide com $(n-1)I(T_i;T_{i-1}) \approx 7 \times 0{,}365$ bits.

Por fim, aplicamos o teste de independência baseado na estatística $G = 2N\ln(2)\,\hat{I} \sim \chi^2_1$ ($\alpha = 5\%$). Na amostra principal, o teste rejeitou com folga a hipótese nula tanto para o par (D,T) ($G = 1422{,}2$, $p \ll 0{,}001$) quanto para dias consecutivos (T_i, T_{i-1}) ($G = 1045{,}5$, $p \ll 0{,}001$), coincidindo exatamente com os resultados de `scipy.stats.chi2_contingency` (com `correction=False`, já que a correção de Yates altera o valor em tabelas 2×2). Repetindo o teste 1 000 vezes em três regimes (Tabela 2), vemos que sob dependência forte o poder é próximo de 100% já para $N = 100$, enquanto no cenário de dependência fraca ($I \approx 0{,}0026$) o poder sobe de 10,6% ($N = 100$) para 75,3% ($N = 2\,000$). Sob independência real, a taxa de rejeição fica próxima dos 5% esperados para $N \geq 500$, mas sobe para 6,9% em $N = 100$, pois 96,2% das tabelas geradas possuem células com contagem esperada menor que 5, comprometendo a aproximação qui-quadrado.

Tabela 2: Taxa de rejeição de H_0 ($\alpha = 5\%$) em 1 000 repetições para diferentes cenários e tamanhos de amostra.

Cenário	$I(D;T)$	N	Rejeições de H_0	Tabelas c/ esperado < 5
Forte	0.2136	100	99.8%	100.0%
Forte	0.2136	500	100.0%	19.2%
Forte	0.2136	2000	100.0%	0.0%
Fraca	0.0026	100	10.6%	76.3%
Fraca	0.0026	500	27.0%	0.0%
Fraca	0.0026	2000	75.3%	0.0%
Independente	-8.65×10^{-17}	100	6.9%	96.2%
Independente	-8.65×10^{-17}	500	4.8%	0.0%
Independente	-8.65×10^{-17}	2000	4.4%	0.0%

2 Tópico 2: Desigualdade de Processamento de Dados

2.1 Cadeia de canais ruidosos e pipeline de classificação

Simulamos o envio de um bit uniforme X através de $k = 10$ canais binários simétricos (BSC) em série, propagando $N = 200\,000$ mensagens independentes. Como a composição de j canais BSC(p)

equivale a um único BSC com probabilidade de inversão $p_j = \frac{1-(1-2p)^j}{2}$, a informação mútua teórica no elo j é $I(X;Y_j) = 1 - H_b(p_j)$. A Figura 2 mostra que $\hat{I}(X;Y_j)$ cai monotonicamente a cada etapa: para $p = 0{,}1$, parte de 0,529 bits no primeiro elo e chega a 0,008 bits no décimo; para ruídos mais altos ($p = 0{,}2$ e 0,3), a informação se dissipa já nos primeiros estágios. Também verificamos na amostra que $\hat{I}(X;Y_2 \mid Y_1) \approx 0$, como esperado pela propriedade de Markov. Em testes auxiliares com amostras pequenas ($N = 200$), observamos pequenas oscilações positivas na curva estimada entre um elo e o seguinte, que desaparecem ao aumentar N, confirmando tratar-se apenas de variância amostral do estimador.

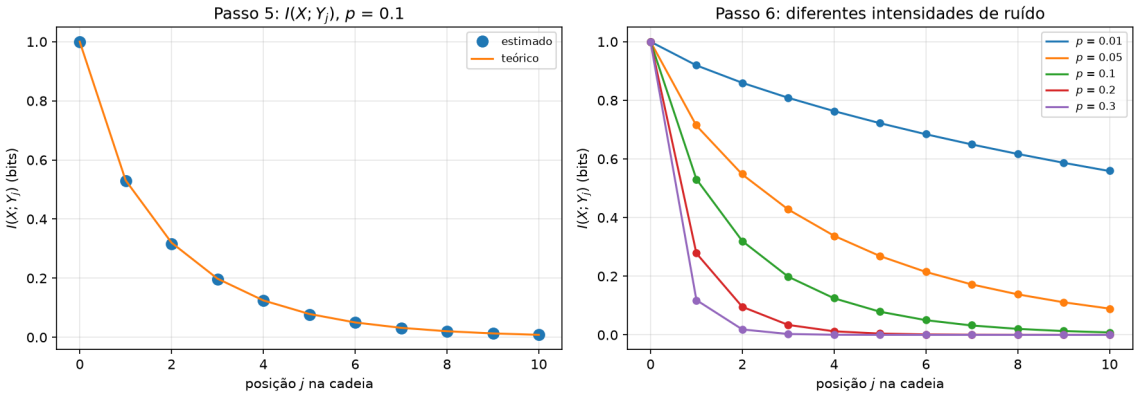


Figura 2: Degradação da informação mútua $I(X;Y_j)$ ao longo dos 10 elos da cadeia para $p = 0{,}1$ (esquerda) e comparação entre diferentes níveis de ruído (direita).

Em seguida, implementamos um pipeline em três etapas inspirado em aprendizado de máquina: o rótulo verdadeiro $X \in \{0,1\}$ gera uma "imagem" ruidosa $\mathbf{Z} \sim \mathcal{N}(\boldsymbol{\mu}_X, \mathbf{I}_{16})$ em $\mathbb{R}^{16}$ (com $\boldsymbol{\mu}_0 = \mathbf{0}$ e $\boldsymbol{\mu}_1 = 0{,}4\,\mathbf{s}$, sendo $\mathbf{s} \in \{-1,+1\}^{16}$), que é comprimida em um vetor de dimensão 4 tomando-se a média de blocos de 4 coordenadas e, por fim, classificada pela menor distância euclidiana às médias comprimidas. Para estimar a informação mútua nos estágios contínuos sem discretizar diretamente os espaços de 16 e 4 dimensões, projetamos os vetores na log-razão de verossimilhança (que é uma estatística suficiente unidimensional e, portanto, preserva $I(X;\mathbf{Z})$) e discretizamos o resultado em 50 faixas de quantis. A Tabela 3 confirma a desigualdade de processamento de dados ao longo do pipeline: a compressão reduz a informação de 0,353 para 0,132 bits (pois parte do sinal se cancela nas médias em bloco), e o classificador final retém 0,088 bits (associado a um erro de classificação de 32,7%), sem conseguir recuperar o que foi perdido na etapa anterior.

Tabela 3: Informação mútua entre o rótulo X e cada estágio do pipeline de classificação.

Estágio	Dimensão	$\hat{I}(X;\cdot)$	$I(X;\cdot)$ teórico
Imagem completa	16	0.3534	0.3527
Representação comprimida	4	0.1319	0.1314
Predição final	1	0.0881	0.0878
Erro de classificação		0.3271	0.3274

2.2 Colapso de modelo em gerações sucessivas

Para simular o fenômeno de colapso de modelo, consideramos uma distribuição original p_{real} sobre $K = 10$ categorias seguindo uma lei de Zipf ($H(p_{\text{real}}) \approx 2{,}87$ bits). Na geração 0, sorteamos n exemplos de p_{real} e calculamos a distribuição empírica q_0; em cada geração seguinte g, sorteamos n novos exemplos a partir de q_{g-1}, repetindo o processo por 100 gerações em 200 trajetórias independentes para $n \in \{20, 100, 1\,000\}$.

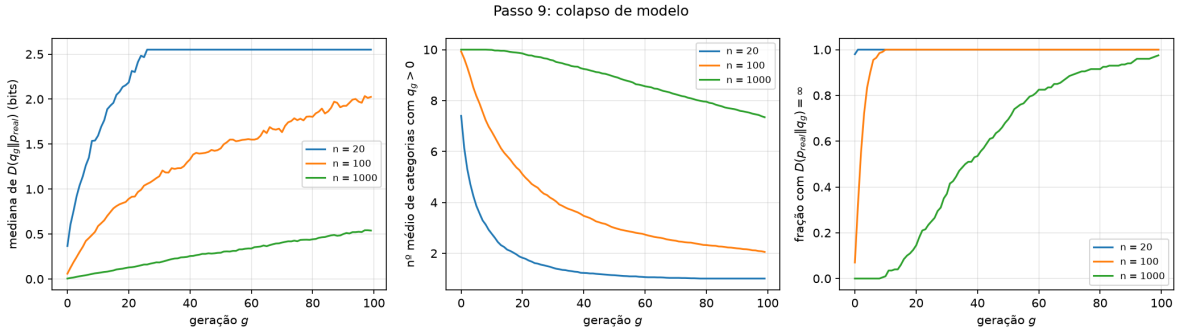


Figura 3: Evolução do colapso de modelo ao longo de 100 gerações para $n \in \{20, 100, 1000\}$: divergência $D(q_g\|p_{\text{real}})$, número médio de categorias sobreviventes e fração de trajetórias com $D(p_{\text{real}}\|q_g) = \infty$.

Como mostra a Figura 3, sempre que uma categoria de menor probabilidade deixa de ser sorteada em uma geração, seu peso passa a ser zero em todas as gerações futuras, levando a divergência $D(p_{\text{real}}\|q_g)$ ao infinito. Acompanhando a divergência reversa $D(q_g\|p_{\text{real}})$ e o número de categorias ativas, fica claro o efeito do tamanho amostral: com $n = 20$, as caudas desaparecem rapidamente e na geração 50 restam em média apenas 1,15 categorias vivas ($H(q_g) \approx 0{,}11$ bits), colapsando a distribuição em um único estado absorvente. Com $n = 1\,000$, o processo é bem mais lento (mantendo 7,34 categorias vivas e $H \approx 2{,}33$ bits na geração 100), mas a perda progressiva de diversidade ocorre de forma inevitável.

3 Tópico 3: Compressão de Dados, AEP e Critério de Kelly

3.1 Comparação de estratégias e Propriedade de Equipartição Assintótica

Simulamos uma temporada de apostas esportivas com $m = 3$ resultados de probabilidades reais $p = (0{,}5;\ 0{,}3;\ 0{,}2)$, o que resulta em entropia $H(p) \approx 1{,}485$ bits, e cotações uniformes justas $o_i = 3$. Geramos 1 000 temporadas independentes de $n = 1\,000$ rodadas cada, acompanhando a evolução do patrimônio em escala logarítmica ($\log_2(S_n/S_0) = \sum_{j=1}^{n} \log_2(b_{X_j} o_{X_j})$) para comparar três estratégias: apostar tudo no favorito ($b = (1, 0, 0)$), distribuir igualmente ($b_i = 1/3$) e apostar segundo o critério de Kelly ($b_i = p_i$).

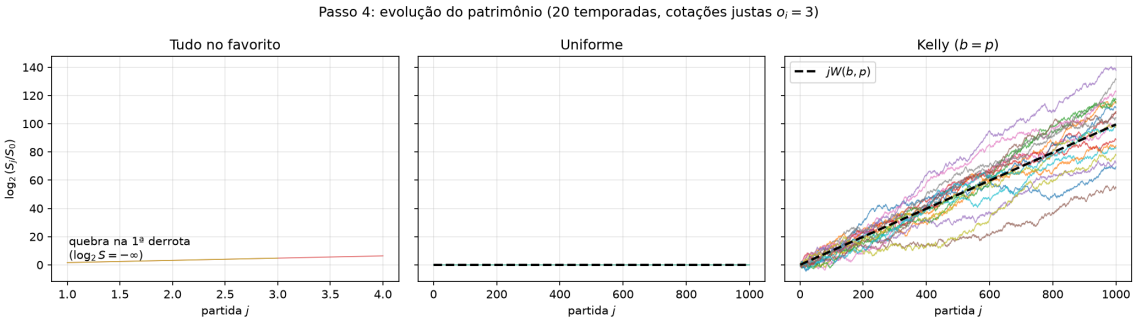


Figura 4: Evolução do logaritmo do patrimônio $\log_2(S_j/S_0)$ ao longo de uma temporada de 1 000 partidas.

Os resultados na Figura 4 e na Tabela 4 evidenciam o contraste entre o retorno médio aritmético e a taxa de crescimento típica. Embora apostar tudo no favorito maximize o valor esperado $\frac{1}{n}\log_2 E[S_n] \approx 0{,}585$ bits (dominado pelo evento de probabilidade $0{,}5^{1000}$ em que o favorito vence todas as partidas), na prática o apostador vai à falência na primeira derrota (100% de ruína nas simulações, $W = -\infty$). A aposta uniforme preserva o capital fixo ($W = 0$ pois

Tabela 4: Desempenho das três estratégias em 1 000 temporadas de $n = 1\,000$ apostas ($o_i = 3$).

Estratégia	$W(b,p)$	Taxa média	Taxa mediana	$S_n < 10^{-3}S_0$	$S_n > 10^{3}S_0$	$\frac{1}{n}\log_2 E[S_n]$
Tudo no favorito	$-\infty$	$-\infty$	$-\infty$	100.0%	0.0%	0.5850
Uniforme	0.0000	0.0000	0.0000	0.0%	0.0%	0.0000
Kelly ($b = p$)	0.0995	0.0998	0.1001	0.0%	100.0%	0.1890

$b_i o_i = 1$), enquanto a estratégia de Kelly apresenta crescimento exponencial consistente à taxa teórica $W^* = \log_2 3 - H(p) = 0{,}0995$ bits por partida (média empírica de 0,0998 bits, superando $10^3 S_0$ em todas as temporadas simuladas).

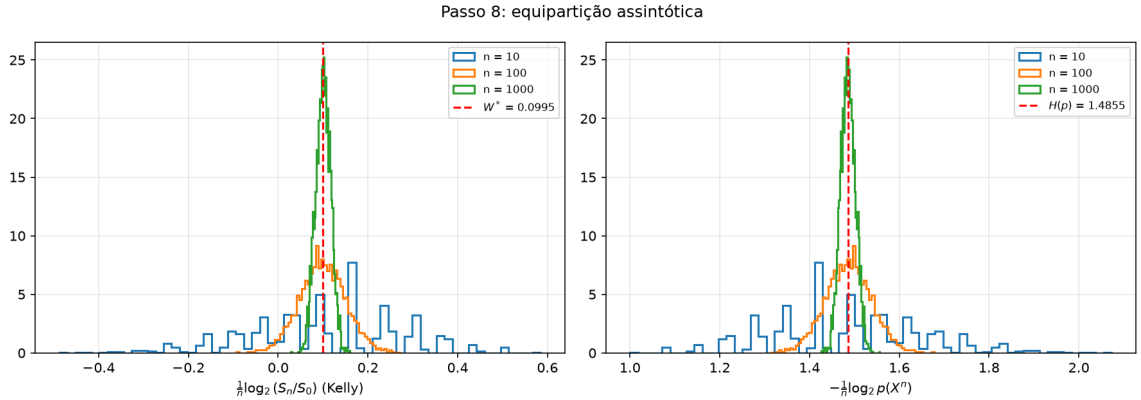


Figura 5: Concentração da taxa de crescimento de Kelly em torno de W^* (esquerda) e da entropia empírica $-\frac{1}{n}\log_2 p(X^n)$ em torno de $H(p)$ (direita) para $n \in \{10, 100, 1000\}$.

A conexão direta com a Propriedade de Equipartição Assintótica (AEP) é mostrada na Figura 5. À medida que a duração da temporada aumenta de $n = 10$ para $n = 1\,000$, a distribuição empírica de $-\frac{1}{n}\log_2 p(X^n)$ concentra-se em torno de $H(p) = 1{,}485$ bits e a taxa de Kelly concentra-se em torno de $W^* = 0{,}0995$ bits, com desvio padrão caindo na razão $1/\sqrt{n}$ (de 0,166 para 0,017). Com $n = 1\,000$, 99,7% das sequências geradas pertencem ao conjunto típico com tolerância $\varepsilon = 0{,}05$.

3.2 Informação lateral e custo de crenças incorretas

Avaliamos em seguida o efeito de uma dica imperfeita Y antes de cada partida, configurada com probabilidade de acerto $P(Y = x \mid X = x) = 0{,}60$, o que fornece informação mútua $I(X;Y) = 0{,}1981$ bits. Utilizando a estratégia de Kelly condicional $b_i(y) = p(i \mid y)$, a taxa de crescimento média no cenário de cotações justas subiu de 0,0995 para 0,2976 bits, um ganho empírico $\Delta W = 0{,}1977$ bits que concorda com $I(X;Y)$. Repetindo o experimento com cotações de uma casa com margem de lucro, $o = (1{,}8;\ 3{,}5;\ 5)$, o apostador sem dica tem taxa negativa ($W^* = -0{,}0549$ bits/aposta), mas a informação lateral proporciona exatamente o mesmo acréscimo $\Delta W = 0{,}1977$ bits, tornando a operação lucrativa ($W = +0{,}1432$ bits).

Por outro lado, quando o apostador baseia suas frações de aposta em probabilidades incorretas $q = (0{,}65;\ 0{,}20;\ 0{,}15)$ (superestimando o favorito), sua taxa de crescimento nas cotações justas cai de 0,0995 para 0,0302 bits por partida. A perda média observada foi de 0,0690 bits, confirmando a previsão teórica $W^* - W(q,p) = D(p\|q) = 0{,}0692$ bits tanto nas cotações justas quanto nas cotações com margem, já que os pagamentos o_i se cancelam na diferença entre os log-retornos das duas estratégias.

4 Tópico 4: Capacidade de Canal e Códigos Corretores de Erro

4.1 Desempenho dos códigos no canal binário simétrico

Modelamos o enlace de comunicação espacial como um canal binário simétrico (BSC) com probabilidade de inversão $p = 0{,}10$, cuja capacidade teórica é $C = 1 - H_b(0{,}10) \approx 0{,}531$ bits por uso do canal. Comparamos três abordagens de transmissão: envio direto sem codificação ($R = 1$), código de repetição com blocos de tamanho ímpar n_r e decisão por maioria ($R = 1/n_r$), e o código de Hamming $(7, 4)$ ($R = 4/7 \approx 0{,}571$), implementado via multiplicação matricial em aritmética módulo 2 e decodificação por síndrome ($s = rH^\top \bmod 2$).

Tabela 5: Taxa de transmissão e erro de bit medido e teórico para $p = 0{,}10$ ($C \approx 0{,}531$).

Método	R	Erro de bit (medido)	Erro de bit (teoria)	$R < C$?
Sem código	1.000	0.1007	0.1000	não
Repetição 3x	0.333	0.0278	0.0280	sim
Repetição 5x	0.200	0.0087	0.0086	sim
Hamming (7,4)	0.571	0.0673	–	não
Hamming, erro de *bloco*	0.571	0.1495	0.1497	não

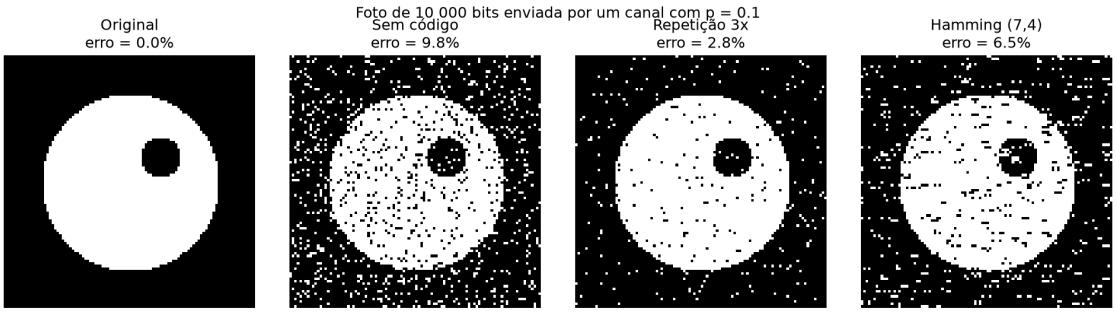


Figura 6: Transmissão de uma imagem binária de 10 000 bits pelo canal BSC ($p = 0{,}10$) usando os diferentes esquemas de codificação.

A Tabela 5 reúne os resultados numéricos para $p = 0{,}10$, e a Figura 6 ilustra visualmente a recuperação de uma imagem de 100×100 pixels. A transmissão direta apresenta erro de bit igual ao próprio ruído do canal (10,1%). O código de Hamming $(7, 4)$ reduz a taxa de erro de bit para 6,73%, mas como corrige apenas 1 erro por bloco de 7 bits, falha sempre que ocorrem 2 ou mais inversões no mesmo bloco (probabilidade teórica de 14,97%, medida em 14,95%), além de operar ligeiramente acima da capacidade ($R = 0{,}571 > C$). Já os códigos de repetição $3\times$ ($R = 0{,}333$) e $5\times$ ($R = 0{,}200$) operam abaixo de C e reduzem a taxa de erro para 2,78% e 0,87% (concordando com a cauda da distribuição binomial), limpando quase completamente a imagem ao custo de enviar 3 a 5 vezes mais bits pelo canal.

4.2 Variação do ruído e o limite do Teorema de Shannon

Na Figura 7 (esquerda), variamos a probabilidade de erro do canal p entre 0,01 e 0,40. Para canais pouco ruidosos ($p \leq 0{,}05$), tanto o código de Hamming quanto os de repetição derrubam a taxa de erro em várias ordens de grandeza; contudo, conforme p aumenta, a ocorrência de múltiplos erros por bloco torna o Hamming ineficaz antes dos códigos de repetição mais longos.

Na Figura 7 (direita), aumentamos o comprimento da repetição de $n_r = 1$ até $n_r = 13$ fixando $p = 0{,}10$. Embora a taxa de erro de bit caia continuamente até $8{,}8 \times 10^{-5}$ em $n_r = 13$, isso só é alcançado porque a taxa de transmissão $R = 1/n_r$ cai para 0,077, afastando-se cada vez mais da capacidade $C \approx 0{,}531$. Esse comportamento contrasta com o Teorema da Codificação de Canal de

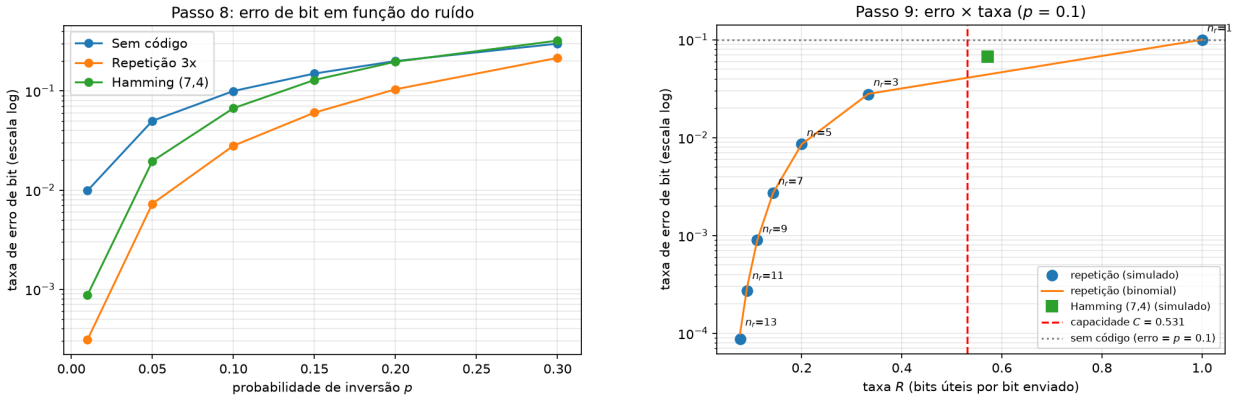


Figura 7: Esquerda: taxa de erro de bit em função do ruído p do canal. Direita: queda do erro no código de repetição para n_r crescente ($p = 0{,}10$), acompanhada da redução da taxa efetiva $R = 1/n_r$ em relação à capacidade C.

Shannon, que garante a existência de códigos capazes de atingir probabilidade de erro arbitrariamente pequena mantendo uma taxa R fixa e próxima de C, desde que $R < C$ e os blocos codificados sejam suficientemente longos.

Por fim, testamos um cenário mais severo com $p = 0{,}20$, onde a capacidade do canal cai para $C \approx 0{,}278$ bits por uso. Nessa condição, todos os esquemas com taxa $R > C$ — sem código ($R = 1$), Hamming ($R = 0{,}571$) e repetição $3\times$ ($R = 0{,}333$) — apresentaram taxas de erro de bit altas (19,9%, 19,7% e 10,4%), fazendo com que nenhuma mensagem de 100 bits chegasse intacta (0,0% de sucesso). Somente ao reduzir a taxa para a região $R < C$, usando repetição $5\times$ ($R = 0{,}200$, erro de 5,8%), $9\times$ ($R = 0{,}111$, erro de 2,0%) e $15\times$ ($R = 0{,}067$, erro de 0,43% e 65,1% de mensagens de 100 bits sem erro), foi possível voltar a controlar os erros de transmissão, ilustrando na prática a barreira imposta pela capacidade de Shannon.