Teoria da Informação - Primeira atividade em grupo

Relatório das simulações

Grupo: Gabriel Takeuchi (13671636) Gabriela Victor (11795381)
Francisco Membrive (12553782) Octavio Carneiro (13831609)
Fernando Lima (13672710)

Resumo da entrega

Concluímos os quatro tópicos, cada um com todos os passos do roteiro. Materiais: `topico1.py`, `topico2.py`, `topico3.py`, `topico4.py` (código; os Tópicos 2 e 3 reaproveitam as funções de entropia, informação mútua e divergência definidas no Tópico 1), pasta `resultados/` (figuras e tabelas, geradas automaticamente pelos scripts com semente fixa) e este relatório. Todas as quantidades foram calculadas a partir de contagens feitas por nós. A função `scipy.stats.chi2_contingency` foi usada apenas como conferência; da `scipy.stats` usamos ainda `chi2.sf` (valor p do teste G) e `binom.sf` (erro teórico do código de repetição).

1 Tópico 1: Entropia, Informação Mútua e Teste de Independência

1.1 O que foi feito

Modelo verdadeiro: prevalência $p(D=1) = 0{,}10$, falso positivo $p(T=1|D=0) = 0{,}05$ e falso negativo $p(T=0|D=1) = 0{,}20$. Os valores teóricos são $H(D) \approx 0{,}469$, $H(T) \approx 0{,}544$, $H(D,T) \approx 0{,}799$, $H(D|T) \approx 0{,}255$ e $I(D;T) \approx 0{,}214$ bits. Simulamos D e depois T condicionalmente a D, contamos as frequências da tabela 2×2 e estimamos as quantidades por *plug-in*.

- **Passo 4:** 500 repetições para cada $N \in \{20, \ldots, 10\,000\}$, tanto no modelo verdadeiro quanto num cenário com D e T independentes.
- **Passo 5:** modelo errado $q(D=1) = 0{,}3$.
- **Passos 6–8:** histórico de testes gerado por uma cadeia de Markov com $P = \left(\begin{smallmatrix} 0{,}9 & 0{,}1 \\ 0{,}2 & 0{,}8 \end{smallmatrix}\right)$, iniciada na distribuição estacionária $\pi = (2/3, 1/3)$. Usamos 200 000 históricos de 8 dias e uma série única de 10^5 dias.
- **Passos 9–10:** teste $G = 2N \ln(2)\, \hat{I}$, com χ^2_1.

1.2 Resultados

Tabela 1: Passos 1–3: teoria × estimativa.

Quantidade	Teórico	Estimado ($N = 5000$)	Diferença
$H(D)$	0.4690	0.4490	-0.0200
$H(T)$	0.5436	0.5077	-0.0359
$H(D,T)$	0.7989	0.7516	-0.0474
$H(D\|T)$	0.2554	0.2438	-0.0115
$I(D;T)$	0.2136	0.2052	-0.0084

Tabela 2: Passo 4: estimativa de $I(D;T)$ em função de N (teórico $\approx 0{,}214$). Últimas colunas: cenário independente ($I = 0$).

N	Média $\hat{I}$	Viés	RMSE	Média $\hat{I}$ (indep.)	$1/(2N \ln 2)$
20	0.2482	+0.0346	0.1957	0.0389	0.0361
50	0.2248	+0.0112	0.1142	0.0182	0.0144
100	0.2179	+0.0043	0.0847	0.0075	0.0072
500	0.2135	-0.0001	0.0382	0.0015	0.0014
2000	0.2141	+0.0005	0.0188	4.21×10^{-4}	3.61×10^{-4}
10000	0.2134	-0.0002	0.0084	7.24×10^{-5}	7.21×10^{-5}

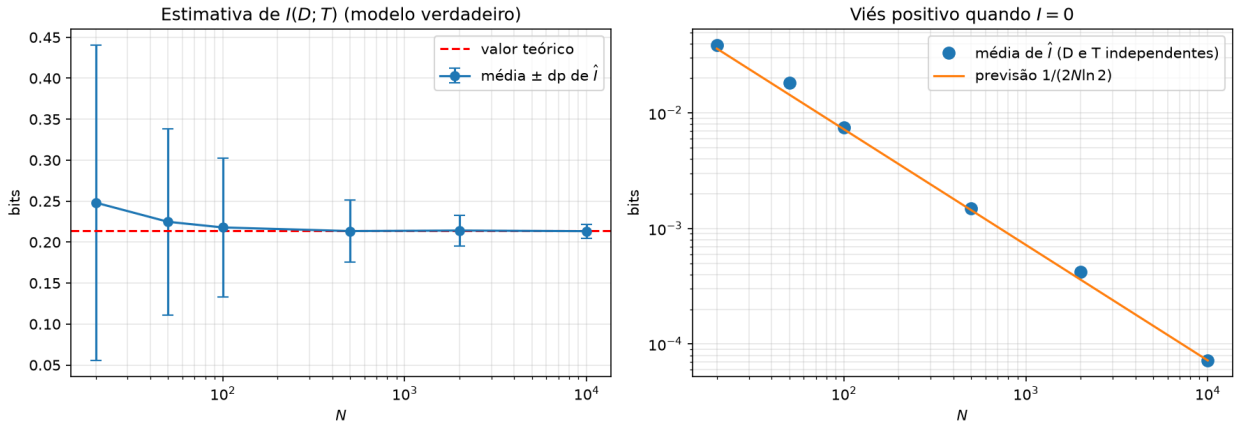


Figura 1: Passo 4. Esquerda: convergência de $\hat{I}$. Direita: viés positivo de $\hat{I}$ sob independência, comparado com $1/(2N \ln 2)$.

Tabela 3: Passo 5: modelo errado $q = (0{,}7; 0{,}3)$.

Quantidade	Bits
$H(p)$	0.4690
$H(p, q)$	0.6368
$H(p, q) - H(p)$	0.1678
$D(p\|\|q)$	0.1678
$D(q\|\|p)$	0.2217
Custo médio na amostra com p ($N = 5000$)	0.4493
Custo médio na amostra com q	0.6292
Excesso medido	0.1799

Tabela 4: Passo 7: regra da cadeia dia a dia ($n = 8$).

Dia i	$\hat{H}(T_i \mid T^{i-1})$	$\hat{H}(T_i \mid T_{i-1})$	Teoria
1	0.9178	0.9178	0.9183
2	0.5532	0.5532	0.5533
3	0.5506	0.5506	0.5533
4	0.5505	0.5505	0.5533
5	0.5520	0.5520	0.5533
6	0.5549	0.5550	0.5533
7	0.5532	0.5534	0.5533
8	0.5507	0.5512	0.5533
Soma	4.7829	4.7838	4.7914
$n\,H(T_1)$ (ingênuo)	7.3426	–	7.3464

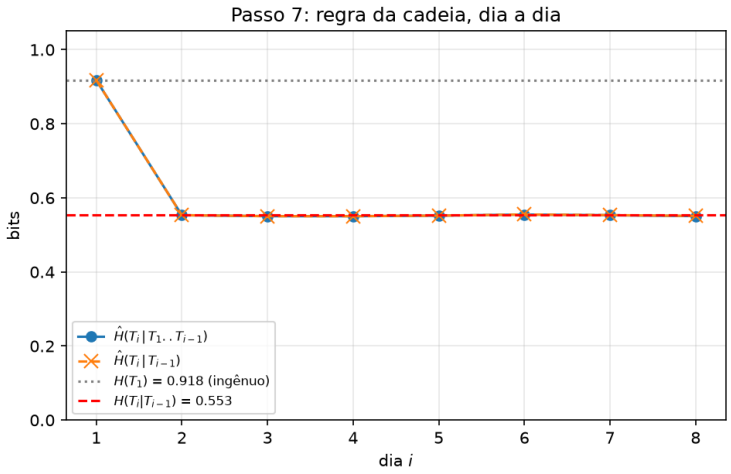


Figura 2: Passo 7: entropia condicional de cada dia.

Tabela 5: Passo 8: economia por explorar a dependência temporal.

	Estimado	Teórico
Custo ingênuo, $n = 8$ dias	7.3426	7.3464
Custo condicional $H(T_1, \ldots, T_n)$	4.7829	4.7914
Economia	2.5597	2.5549
$(n-1)\,I(T_i; T_{i-1})$	2.5269	2.5549
Economia por dia (1 paciente, 10^5 dias)	0.3610	0.3650

Tabela 6: Passo 9: testes de independência ($\alpha = 0{,}05$).

Teste	N	$\hat{I}$	G	G (scipy)	g.l.	valor p	Decisão
D vs T	5000	0.2052	1422.20	1422.20	1	3.15×10^{-311}	rejeita H_0
T_i vs T_{i-1}	1999	0.3773	1045.52	1045.52	1	2.29×10^{-229}	rejeita H_0

Tabela 7: Passo 10: fração de rejeições em 1000 repetições.

Cenário	$I(D;T)$	N	Rejeições de H_0	Tabelas c/ esperado < 5
Forte	0.2136	100	99.8%	100.0%
Forte	0.2136	500	100.0%	19.2%
Forte	0.2136	2000	100.0%	0.0%
Fraca	0.0026	100	10.6%	76.3%
Fraca	0.0026	500	27.0%	0.0%
Fraca	0.0026	2000	75.3%	0.0%
Independente	-8.65×10^{-17}	100	6.9%	96.2%
Independente	-8.65×10^{-17}	500	4.8%	0.0%
Independente	-8.65×10^{-17}	2000	4.4%	0.0%

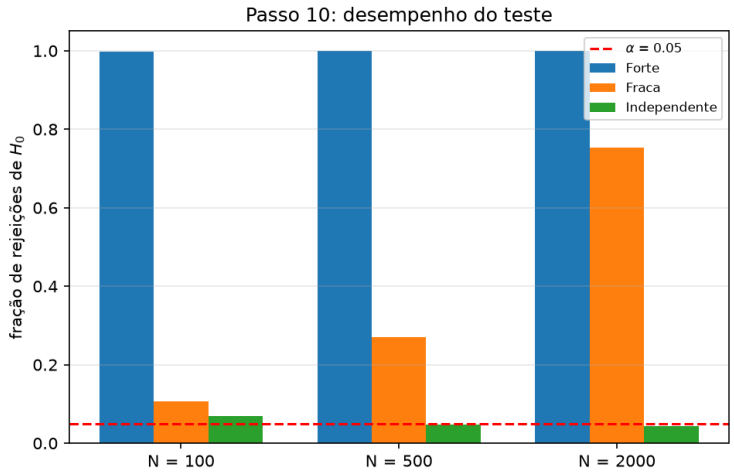


Figura 3: Passo 10: poder do teste (cenários forte e fraco) e taxa de erro tipo I (cenário independente).

1.3 As previsões teóricas se confirmaram?

- **Passo 3:** as estimativas ficaram próximas dos valores teóricos. As identidades $H(D|T) = H(D,T) - H(T)$ e $I = H(D) - H(D|T) = H(T) - H(T|D)$ valem exatamente também para as estimativas.
- **Passo 4:** o erro diminui com N. Para N pequeno, $\hat{I}$ é sistematicamente maior que o valor verdadeiro. Sob independência, $E[\hat{I}] \approx \text{g.l.}/(2N \ln 2)$, que é a média da χ^2_1 reescalada: cerca de 0,036 bit para $N = 20$, um valor que não é desprezível.
- **Passo 5:** $H(p,q) - H(p) = D(p\|q) \approx 0{,}168$ bit. O custo médio medido na amostra (comprimentos ideais $-\log_2 q(d)$) dá um excesso de $\approx 0{,}180$ bit, próximo do teórico; a diferença vem da frequência amostral de $D = 1$ (9,4% em vez de 10%). A divergência não é simétrica: $D(q\|p) \approx 0{,}222 \neq D(p\|q)$.
- **Passo 7:** $\hat{H}(T_i|T_1,\ldots,T_{i-1}) \approx \hat{H}(T_i|T_{i-1}) \approx 0{,}553$ bit para $i \geq 2$. Ou seja, dado o dia anterior, os dias mais antigos não acrescentam informação (propriedade de Markov). A soma das condicionais reproduz $H(T_1,\ldots,T_8) \approx 4{,}79$ bits, contra $8H(T_1) \approx 7{,}35$ bits no esquema ingênuo.
- **Passo 8:** a economia é de $(n-1)\,I(T_i;T_{i-1}) \approx 7 \times 0{,}365 \approx 2{,}55$ bits por histórico de 8 dias. Equivalentemente, a economia é de $\approx 0{,}365$ bit por dia num histórico longo.
- **Passo 9:** as estatísticas G calculadas por nós coincidem com as da `chi2_contingency` (opção `lambda_="log-likelihood"`). Atenção: só há coincidência com `correction=False`, pois a

função aplica por padrão a correção de Yates em tabelas 2×2. As duas dependências (D–T e T_{i-1}–T_i) foram detectadas com folga.

- **Passo 10:** no cenário forte, o teste rejeita H_0 praticamente sempre. No cenário fraco ($I \approx 0{,}003$ bit), o poder cresce com N. No cenário independente, a fração de rejeições ficou próxima de $\alpha = 5\%$, que é a taxa de erro tipo I prevista. Para $N = 100$, muitas tabelas têm contagem esperada < 5, e a aproximação qui-quadrado fica menos confiável.

2 Tópico 2: Desigualdade de Processamento de Dados

2.1 O que foi feito

- **Passos 1–6:** X é um bit uniforme, passado por $k = 10$ canais BSC(p) em série, com $N = 200\,000$ mensagens. Como j BSCs em série equivalem a um BSC com $p_j = \frac{1-(1-2p)^j}{2}$, temos $I(X;Y_j) = 1 - H_b(p_j)$. Medimos também $I(X;Y_2|Y_1)$ para conferir a propriedade de Markov.
- **Passos 7–8:** o rótulo X (gato/cachorro) gera uma "imagem" $\mathbf{Z} \sim \mathcal{N}(\boldsymbol{\mu}_X, \mathbf{I}_{16})$, com $\boldsymbol{\mu}_0 = \mathbf{0}$ e $\boldsymbol{\mu}_1 = 0{,}4\,\mathbf{s}$ ($\mathbf{s}$ é um padrão de sinais ± 1). A compressão toma médias de blocos de 4 coordenadas ($16 \to 4$). A predição usa a média mais próxima no espaço comprimido.
- **Passo 9:** colapso de modelo com $K = 10$ categorias (distribuição de Zipf). Cada geração estima as frequências relativas de uma amostra de tamanho $n \in \{20, 100, 1000\}$ e gera a próxima. Fizemos 100 gerações e 200 repetições.

Como estimamos I para a imagem contínua (dúvida que tínhamos). Discretizar diretamente 16 coordenadas é inviável: com B caixas por coordenada seriam B^{16} células. Contornamos isso com a própria desigualdade de processamento. A log-razão de verossimilhança $L(\mathbf{z}) = \log \frac{p(\mathbf{z}|X=1)}{p(\mathbf{z}|X=0)}$ é uma estatística suficiente para X. Por isso $X \to \mathbf{Z} \to L$ e $X \to L \to \mathbf{Z}$ são ambas cadeias de Markov, e portanto $I(X;\mathbf{Z}) = I(X;L)$. L é unidimensional: discretizamos em 50 caixas de quantis e usamos o estimador *plug-in*. O valor teórico vem de $L|X \sim \mathcal{N}(\pm d^2/2, d^2)$, em que d^2 é a distância de Mahalanobis entre as médias, e foi calculado por integração numérica. Na imagem completa, $d^2 = 2{,}56$. Na representação comprimida, $d^2 = 0{,}8$, porque parte do padrão $\mathbf{s}$ se cancela nas médias de blocos.

2.2 Resultados

Tabela 8: Passo 4: $I(X;Y_j)$ ao longo da cadeia ($p = 0{,}1$).

Estágio j	$\hat{I}(X;Y_j)$	$I(X;Y_j)$ teórico	Diferença
0	1.0000	1.0000	-0.00000
1	0.5292	0.5310	-0.00185
2	0.3170	0.3199	-0.00288
3	0.1960	0.1984	-0.00232
4	0.1239	0.1247	-0.00072
5	0.0777	0.0789	-0.00124
6	0.0506	0.0502	+0.00044
7	0.0318	0.0320	-0.00013
8	0.0201	0.0204	-0.00032
9	0.0124	0.0130	-0.00064
10	0.0081	0.0083	-0.00021
$\hat{I}(X;Y_2\|Y_1)$	9.58×10^{-7}	0	
$\hat{I}(X;Y_1\|Y_2)$	0.2121		

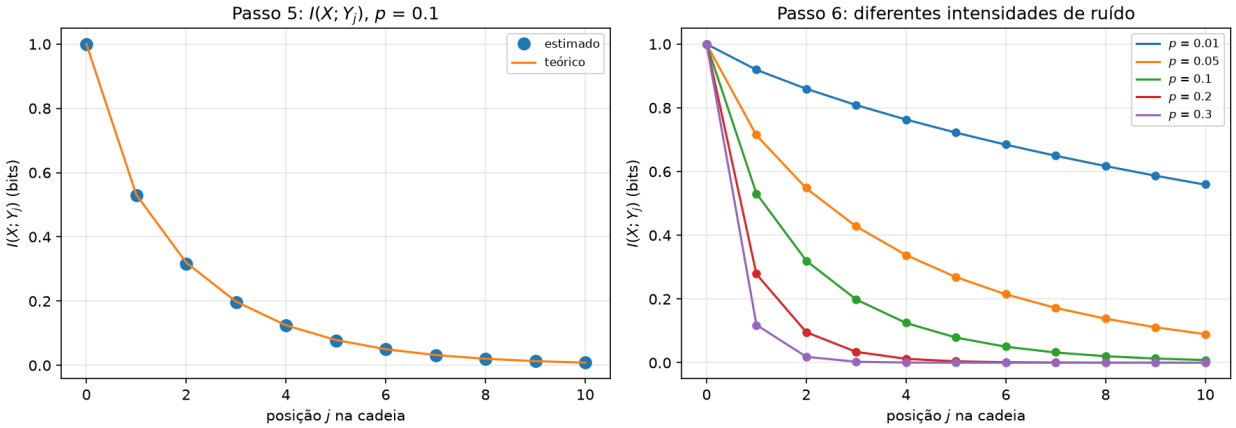


Figura 4: Passos 5–6: degradação da informação elo após elo (pontos: simulação; linhas: teoria).

Tabela 9: Passo 8: rótulo → imagem → compressão → predição.

Estágio	Dimensão	$\hat{I}(X;\cdot)$	$I(X;\cdot)$ teórico
Imagem completa	16	0.3534	0.3527
Representação comprimida	4	0.1319	0.1314
Predição final	1	0.0881	0.0878
Erro de classificação		0.3271	0.3274

Tabela 10: Passo 9: colapso de modelo.

n/geração	Geração	Mediana $D(q_g\|\|p)$	$D(p\|\|q_g) = \infty$	Categorias vivas	$H(q_g)$ média
20	0	0.3669	98%	7.40	2.518
20	9	1.5396	100%	2.92	1.209
20	49	2.5504	100%	1.15	0.111
20	99	2.5504	100%	1.01	0.005
100	0	0.0599	7%	9.93	2.809
100	9	0.5248	99%	6.97	2.288
100	49	1.4331	100%	3.04	1.216
100	99	2.0252	100%	2.06	0.694
1000	0	0.0058	0%	10.00	2.869
1000	9	0.0637	0%	9.99	2.816
1000	49	0.2911	68%	8.97	2.602
1000	99	0.5393	98%	7.34	2.330

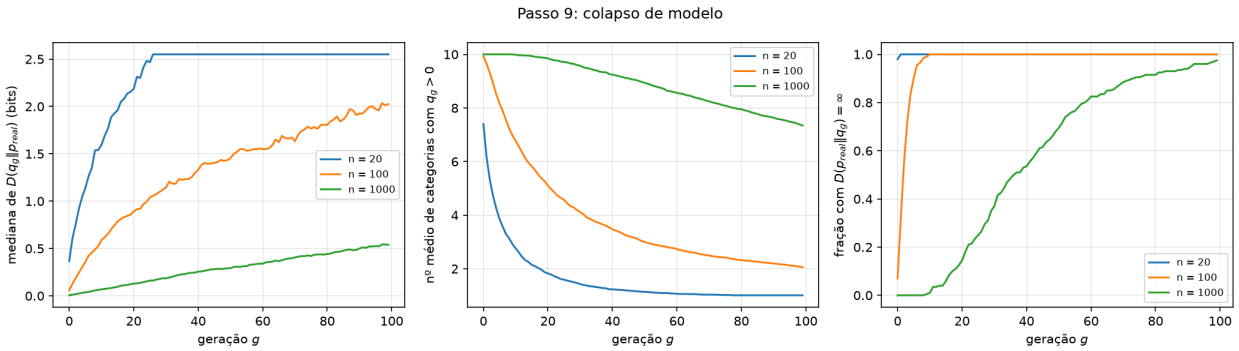


Figura 5: Passo 9: divergência, categorias sobreviventes e fração de trajetórias com $D(p_{real} \| q_g) = \infty$.

2.3 As previsões teóricas se confirmaram?

- **Passos 4–5:** $\hat{I}(X;Y_j)$ é não crescente e acompanha $1 - H_b(p_j)$: de $\approx 0{,}531$ bit ($j = 1$) para $\approx 0{,}008$ bit ($j = 10$). Medimos $\hat{I}(X;Y_2|Y_1) \approx 0$, como exige uma cadeia de Markov, enquanto $\hat{I}(X;Y_1|Y_2) > 0$.
- **Ruído de estimação:** num experimento à parte com $p = 0{,}2$ e N pequeno, aparecem "solavancos" para cima na curva: em média 2,60, 1,54 e 0,52 por cadeia de 10 elos para $N = 200$, 2 000 e 20 000 (e nenhum na simulação principal, com $N = 200\,000$). Eles diminuem quando N aumenta, o que confirma que são flutuação amostral das estimativas, e não violações da desigualdade.
- **Passo 6:** quanto maior p, mais rápida a queda, pois $(1 - 2p)^j$ decai mais depressa. Com $p = 0{,}3$, a informação some em poucos elos.
- **Passo 8:** $I(X;\text{imagem}) \geq I(X;\text{comprimida}) \geq I(X;\text{predição})$, com a predição em $1 - H_b(P_e) \approx 0{,}088$ bit ($P_e \approx 0{,}327$). Nenhuma regra de decisão aplicada à representação comprimida recupera a informação perdida na compressão.
- **Passo 9:** a cada geração, categorias raras podem não ser sorteadas. Quando isso acontece, ficam com probabilidade zero para sempre, e $D(p_{real} \| q_g) = \infty$. Por isso acompanhamos também $D(q_g \| p_{real})$, o número de categorias vivas e $H(q_g)$. A diversidade (entropia) cai geração após geração, muito mais depressa com amostras pequenas ($n = 20$). A longo prazo, cada trajetória tende a se concentrar numa única categoria (estado absorvente), embora $E[q_g] = p_{real}$ em média. Esse é o mecanismo do colapso de modelo.

3 Tópico 3: Compressão, AEP e Critério de Kelly

3.1 O que foi feito

- **Modelo:** $m = 3$ resultados, com $p = (0{,}5;\ 0{,}3;\ 0{,}2)$ e $H(p) \approx 1{,}485$ bits. Usamos cotações justas $o_i = 3$ e cotações de uma casa com margem, $o = (1{,}8;\ 3{,}5;\ 5)$, para verificar que os resultados sobre divergência e informação lateral não dependem das cotações.
- **Simulação:** 1000 temporadas de 1000 partidas, geradas como uma matriz temporadas × rodadas. O patrimônio foi acompanhado em escala log (soma acumulada de $\log_2 b_X o_X$).
- **Informação lateral (Passo 9):** $P(Y = x|X = x) = 0{,}6$, com sorteio pelo vetor achatado da conjunta.
- **Crença errada (Passo 11):** $q = (0{,}65;\ 0{,}2;\ 0{,}15)$.

3.2 Resultados

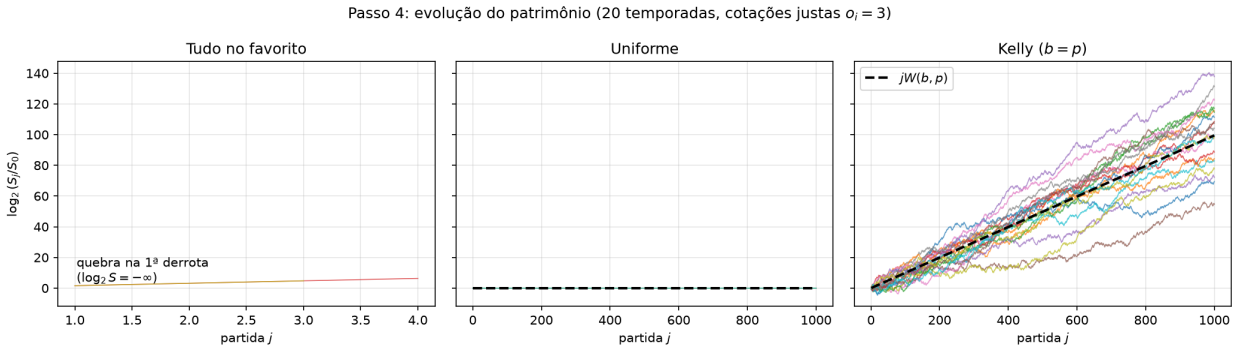


Figura 6: Passo 4: trajetórias de $\log_2(S_j/S_0)$.

Tabela 11: Passos 6–7 ($o_i = 3$, $n = 1000$, 1000 temporadas).

Estratégia	$W(b,p)$	Taxa média	Taxa mediana	$S_n < 10^{-3}S_0$	$S_n > 10^{3}S_0$	$\frac{1}{n}\log_2 E[S_n]$
Tudo no favorito	$-\infty$	$-\infty$	$-\infty$	100.0%	0.0%	0.5850
Uniforme	0.0000	0.0000	0.0000	0.0%	0.0%	0.0000
Kelly ($b = p$)	0.0995	0.0998	0.1001	0.0%	100.0%	0.1890

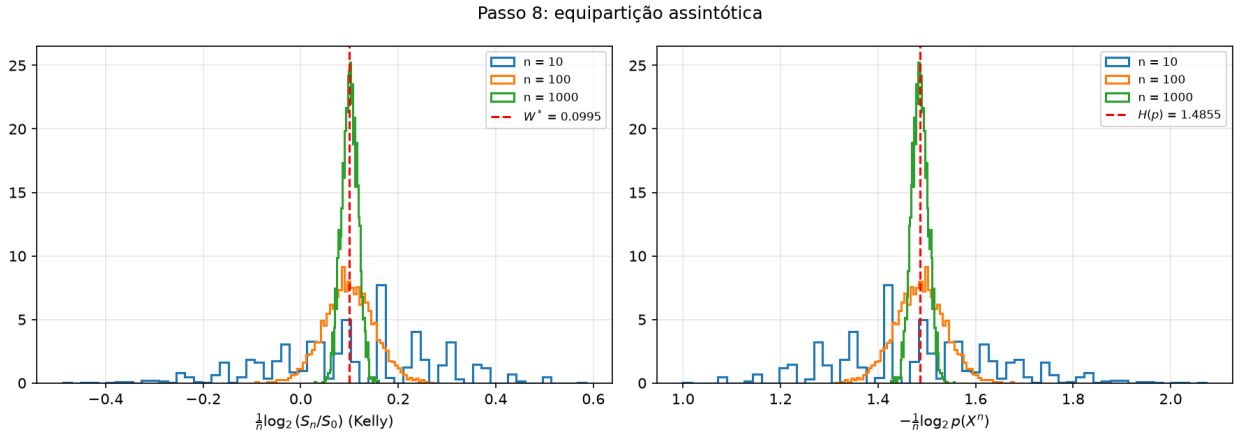


Figura 7: Passo 8: concentração da taxa de crescimento de Kelly em torno de W^* e de $-\frac{1}{n}\log_2 p(X^n)$ em torno de $H(p)$.

Tabela 12: Passo 8: concentração com n crescente.

n	Taxa Kelly (média)	dp	dp teórico	$-\frac{1}{n}\log_2 p(X^n)$ (média)	dp	Típicas ($\varepsilon = 0.05$)
10	0.1025	0.1657	0.1664	1.4824	0.1657	17.5%
100	0.0986	0.0518	0.0526	1.4863	0.0518	67.0%
1000	0.0998	0.0168	0.0166	1.4852	0.0168	99.7%

Tabela 13: Passos 9–10: ganho com informação lateral.

Cotações	W^* sem dica	W com dica	ΔW teórico	ΔW empírico	$I(X;Y)$
Justas $o_i = 3$	0.0995	0.2976	0.1981	0.1977	0.1981
Casa (1,8; 3,5; 5)	-0.0549	0.1432	0.1981	0.1977	0.1981

Tabela 14: Passo 11: custo de apostar com a distribuição errada q.

Cotações	W^*	$W(q,p)$	Perda teórica	Perda empírica	$D(p\|\|q)$
Justas $o_i = 3$	0.0995	0.0302	0.0692	0.0690	0.0692
Casa (1,8; 3,5; 5)	-0.0549	-0.1241	0.0692	0.0690	0.0692

3.3 As previsões teóricas se confirmaram?

- **Tudo no favorito:** $W = -\infty$. O apostador quebra na primeira partida em que o favorito não vence, com probabilidade $1-0{,}5^n$. Paradoxalmente, é a estratégia de maior valor *esperado* ($E[S_n] = 1{,}5^n S_0$): a média é dominada por uma trajetória rara e astronômica que nunca observamos.
- **Uniforme:** com $o_i = 3$, temos $b_i o_i = 1$ e o patrimônio fica parado ($W = 0$).
- **Kelly:** a taxa empírica concordou com $W^* = \log_2 3 - H(p) \approx 0{,}0995$ bit por aposta.
- **Passo 8 (AEP):** as distribuições de $\frac{1}{n}\log_2 S_n$ e de $-\frac{1}{n}\log_2 p(X^n)$ se concentram em torno de W^* e de $H(p)$, com desvio padrão caindo como $1/\sqrt{n}$. A fração de sequências típicas tende a 1.
- **Passo 10:** $\Delta W \approx I(X;Y) \approx 0{,}198$ bit nos dois conjuntos de cotações. Com a casa com margem, Kelly sem dica perde dinheiro ($W^* \approx -0{,}055$), mas a dica torna a aposta lucrativa ($\approx +0{,}143$).
- **Passo 11:** a perda ficou em $\approx D(p\|q) \approx 0{,}069$ bit por aposta, igual para as duas cotações. De fato, partida a partida, a diferença dos incrementos é $\log_2(p_X/q_X)$, e as cotações se cancelam.

4 Tópico 4: Capacidade de Canal e Códigos Corretores

4.1 O que foi feito

O enlace Terra–Marte foi modelado como canal binário simétrico (BSC): cada bit é invertido, independentemente, com probabilidade p. A simulação é bit a bit: sorteia-se um uniforme por bit, compara-se com p e aplica-se XOR. A capacidade é

$$C = 1 - H_b(p), \qquad H_b(p) = -p\log_2 p - (1-p)\log_2(1-p).$$

Comparamos três esquemas:

- sem código ($R = 1$);
- repetição com n_r ímpar e votação majoritária ($R = 1/n_r$);
- Hamming $(7,4)$ ($R = 4/7$), com codificação $c = dG \bmod 2$ e decodificação por síndrome $s = rH^\top \bmod 2$, cujo valor binário indica a posição do erro.

Antes da simulação, o Hamming foi testado inserindo um erro em cada uma das 7 posições das 16 mensagens possíveis: todos os erros foram corrigidos. O erro da repetição foi conferido com a cauda binomial $P(X \geq \lfloor n_r/2 \rfloor + 1)$, com $X \sim \mathrm{Bin}(n_r, p)$.

4.2 Resultados

Com $p = 0{,}1$, temos $C \approx 0{,}531$. A Tabela 15 compara os três esquemas, e a Figura 8 mostra o efeito sobre uma "foto".

Tabela 15: Passo 7 ($p = 0{,}1$, $C \approx 0{,}531$).

Método	R	Erro de bit (medido)	Erro de bit (teoria)	$R < C$?
Sem código	1.000	0.1007	0.1000	não
Repetição 3x	0.333	0.0278	0.0280	sim
Repetição 5x	0.200	0.0087	0.0086	sim
Hamming (7,4)	0.571	0.0673	–	não
Hamming, erro de *bloco*	0.571	0.1495	0.1497	não

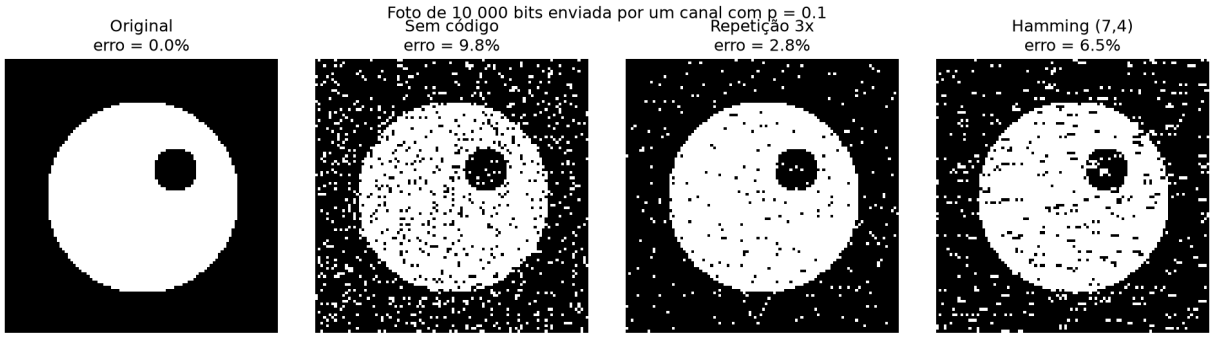


Figura 8: Imagem de 10 000 bits transmitida pelos três esquemas ($p = 0{,}1$).

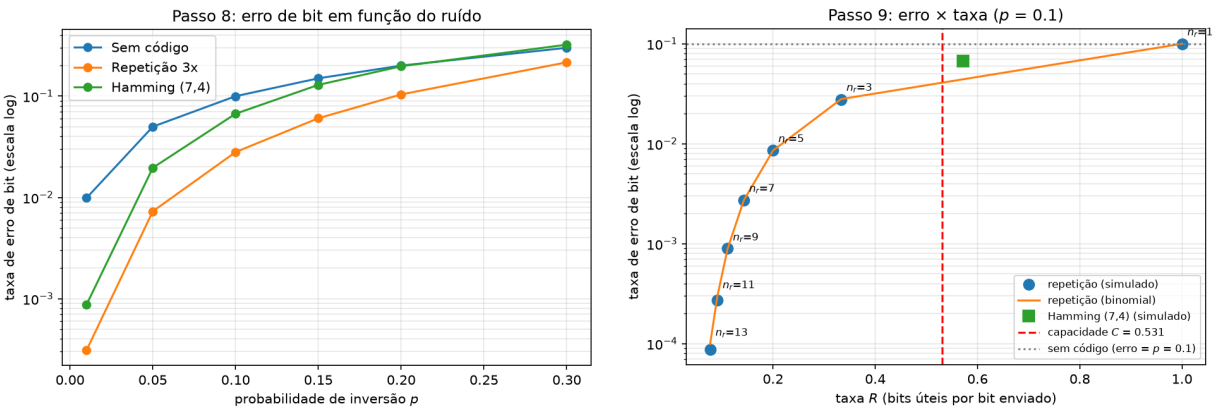


Figura 9: Esquerda: erro de bit em função de p (Passo 8). Direita: erro em função da taxa R, com a capacidade C em vermelho (Passo 9).

Tabela 16: Passo 9: repetição com n_r crescente ($p = 0{,}1$).

n_r	$R = 1/n_r$	Erro (medido)	Erro (binomial)	Nº de erros
1	1.000	0.1000	0.1000	100045
3	0.333	0.0278	0.0280	27813
5	0.200	0.0086	0.0086	8607
7	0.143	0.0027	0.0027	2735
9	0.111	8.99×10^{-4}	8.91×10^{-4}	899
11	0.091	2.71×10^{-4}	2.96×10^{-4}	271
13	0.077	8.80×10^{-5}	9.93×10^{-5}	88

Tabela 17: Passo 10: $p = 0{,}2$, $C \approx 0{,}278$.

Método	R	$R > C$?	Erro de bit	Mensagens de 100 bits sem erro
Sem código	1.000	sim	0.1994	0.0%
Hamming (7,4)	0.571	sim	0.1967	0.0%
Repetição 3x	0.333	sim	0.1042	0.0%
Repetição 5x	0.200	não	0.0578	0.2%
Repetição 9x	0.111	não	0.0196	14.2%
Repetição 15x	0.067	não	0.0043	65.1%

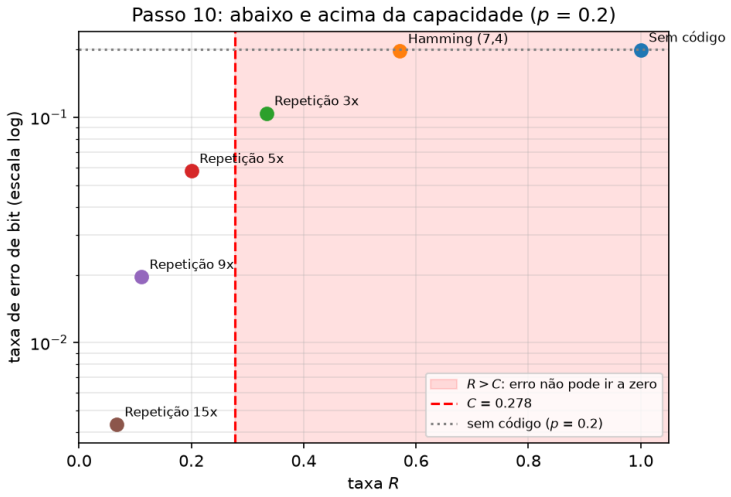


Figura 10: Passo 10: a região $R > C$ está sombreada.

4.3 As previsões teóricas se confirmaram?

- **Sem código:** o erro medido ficou próximo de p, como previsto.
- **Repetição:** o erro medido concordou com a binomial (teoria: 0,028 para $n_r = 3$ e $\approx 0{,}0086$ para $n_r = 5$ com $p = 0{,}1$).
- **Hamming:** o erro de bloco concordou com $P(\geq 2 \text{ erros em } 7) \approx 0{,}150$. Com $p = 0{,}1$, o Hamming tem $R = 0{,}571 > C = 0{,}531$, ou seja, já opera acima da capacidade.
- **Passo 8:** para p pequeno, os códigos reduzem drasticamente o erro. Conforme p cresce, a vantagem diminui, e o Hamming (que corrige só 1 erro por bloco de 7) é o primeiro a perdê-la.

- **Passo 9:** o erro da repetição cai com n_r, mas apenas porque $R = 1/n_r \to 0$. Isso *não* é a promessa de Shannon, que garante erro arbitrariamente pequeno com *taxa fixa* $R < C$, usando códigos melhores com blocos longos.
- **Passo 10:** todos os esquemas com $R > C$ mantiveram erro de bit alto, e quase nenhuma mensagem de 100 bits chegou intacta, o que é coerente com a parte inversa do teorema. Ressalva: testamos apenas os nossos códigos; o teorema vale para *qualquer* código.