Teoria da Informação — Primeira atividade em grupo

Relatório das simulações

Grupo: Nome 1 (NUSP) Nome 2 (NUSP) Nome 3 (NUSP) Nome 4 (NUSP)
Nome 5 (NUSP) Nome 6 (NUSP)

Resumo da entrega

Concluímos os quatro tópicos, cada um com todos os passos do roteiro. Materiais: `topico1.py`, `topico2.py`, `topico3.py`, `topico4.py` (código; os Tópicos 2 e 3 reaproveitam as funções de entropia, informação mútua e divergência definidas no Tópico 1), pasta `resultados/` (figuras e tabelas, geradas automaticamente pelos scripts com semente fixa) e este relatório. Todas as quantidades foram calculadas a partir de contagens feitas por nós; funções de biblioteca (`scipy.stats.chi2_contingency`, `scipy.stats.binom`) foram usadas apenas como conferência.

1 Tópico 1: Entropia, Informação Mútua e Teste de Independência

1.1 O que foi feito

Modelo verdadeiro: prevalência $p(D = 1) = 0{,}10$, falso positivo $p(T = 1|D = 0) = 0{,}05$ e falso negativo $p(T = 0|D = 1) = 0{,}20$. Os valores teóricos são $H(D) \approx 0{,}469$, $H(T) \approx 0{,}544$, $H(D, T) \approx 0{,}799$, $H(D|T) \approx 0{,}255$ e $I(D;T) \approx 0{,}214$ bits. Simulamos D e depois T condicionalmente a D, contamos as frequências da tabela 2×2 e estimamos as quantidades por *plug-in*.

- **Passo 4:** 500 repetições para cada $N \in \{20, \ldots, 10\,000\}$, tanto no modelo verdadeiro quanto num cenário com D e T independentes.
- **Passo 5:** modelo errado $q(D = 1) = 0{,}3$.
- **Passos 6–8:** histórico de testes gerado por uma cadeia de Markov com $P = \left(\begin{smallmatrix} 0{,}9 & 0{,}1 \\ 0{,}2 & 0{,}8 \end{smallmatrix}\right)$, iniciada na distribuição estacionária $\pi = (2/3, 1/3)$. Usamos 200 000 históricos de 8 dias e uma série única de 10^5 dias.
- **Passos 9–10:** teste $G = 2N \ln(2)\, \hat{I}$, com χ^2_1.

1.2 Resultados

Tabela 1: Passos 1–3: teoria × estimativa.

Quantidade	Teórico	Estimado ($N = 5000$)	Diferença
$H(D)$	0.4690	0.4490	-0.0200
$H(T)$	0.5436	0.5077	-0.0359
$H(D, T)$	0.7989	0.7516	-0.0474
$H(D\|T)$	0.2554	0.2438	-0.0115
$I(D;T)$	0.2136	0.2052	-0.0084

Tabela 2: Passo 4: estimativa de $I(D;T)$ em função de N (teórico $\approx 0{,}214$). Últimas colunas: cenário independente ($I = 0$).

N	Média $\hat{I}$	Viés	RMSE	Média $\hat{I}$ (indep.)	$1/(2N \ln 2)$
20	0.2482	+0.0346	0.1957	0.0389	0.0361
50	0.2248	+0.0112	0.1142	0.0182	0.0144
100	0.2179	+0.0043	0.0847	0.0075	0.0072
500	0.2135	-0.0001	0.0382	0.0015	0.0014
2000	0.2141	+0.0005	0.0188	4.21×10^{-4}	3.61×10^{-4}
10000	0.2134	-0.0002	0.0084	7.24×10^{-5}	7.21×10^{-5}

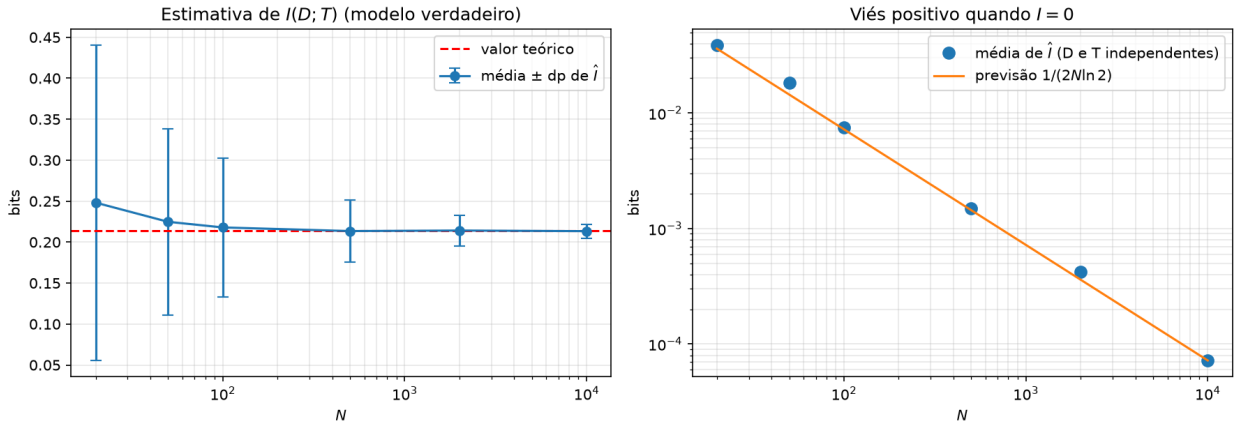


Figura 1: Passo 4. Esquerda: convergência de $\hat{I}$. Direita: viés positivo de $\hat{I}$ sob independência, comparado com $1/(2N \ln 2)$.

Tabela 3: Passo 5: modelo errado $q = (0{,}7; 0{,}3)$.

Quantidade	Bits
$H(p)$	0.4690
$H(p, q)$	0.6368
$H(p, q) - H(p)$	0.1678
$D(p\|\|q)$	0.1678
$D(q\|\|p)$	0.2217
Custo médio na amostra com p ($N = 5000$)	0.4493
Custo médio na amostra com q	0.6292
Excesso medido	0.1799

Tabela 4: Passo 7: regra da cadeia dia a dia ($n = 8$).

Dia i	$\hat{H}(T_i \mid T^{i-1})$	$\hat{H}(T_i \mid T_{i-1})$	Teoria
1	0.9178	0.9178	0.9183
2	0.5532	0.5532	0.5533
3	0.5506	0.5506	0.5533
4	0.5505	0.5505	0.5533
5	0.5520	0.5520	0.5533
6	0.5549	0.5550	0.5533
7	0.5532	0.5534	0.5533
8	0.5507	0.5512	0.5533
Soma	4.7829	4.7838	4.7914
$n\,H(T_1)$ (ingênuo)	7.3426	–	7.3464

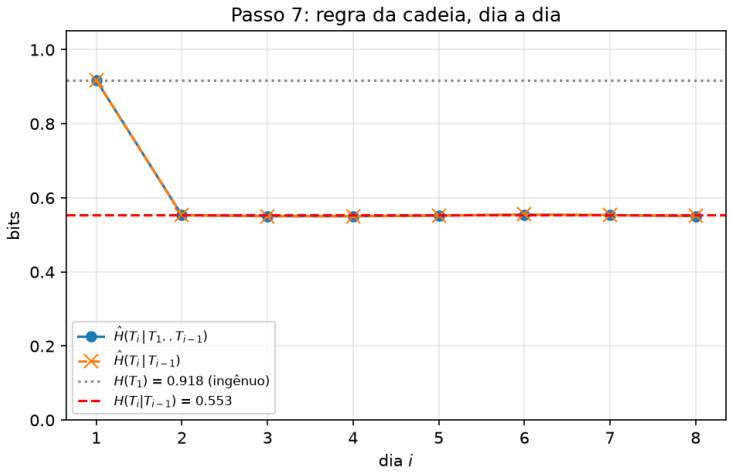


Figura 2: Passo 7: entropia condicional de cada dia.

Tabela 5: Passo 8: economia por explorar a dependência temporal.

	Estimado	Teórico
Custo ingênuo, $n = 8$ dias	7.3426	7.3464
Custo condicional $H(T_1, \ldots, T_n)$	4.7829	4.7914
Economia	2.5597	2.5549
$(n-1)\,I(T_i; T_{i-1})$	2.5269	2.5549
Economia por dia (1 paciente, 10^5 dias)	0.3610	0.3650

Tabela 6: Passo 9: testes de independência ($\alpha = 0{,}05$).

Teste	N	$\hat{I}$	G	G (scipy)	g.l.	valor p	Decisão
D vs T	5000	0.2052	1422.20	1422.20	1	3.15×10^{-311}	rejeita H_0
T_i vs T_{i-1}	1999	0.3773	1045.52	1045.52	1	2.29×10^{-229}	rejeita H_0

Tabela 7: Passo 10: fração de rejeições em 1000 repetições.

Cenário	$I(D;T)$	N	Rejeições de H_0	Tabelas c/ esperado < 5
Forte	0.2136	100	99.8%	100.0%
Forte	0.2136	500	100.0%	19.2%
Forte	0.2136	2000	100.0%	0.0%
Fraca	0.0026	100	10.6%	76.3%
Fraca	0.0026	500	27.0%	0.0%
Fraca	0.0026	2000	75.3%	0.0%
Independente	-8.65×10^{-17}	100	6.9%	96.2%
Independente	-8.65×10^{-17}	500	4.8%	0.0%
Independente	-8.65×10^{-17}	2000	4.4%	0.0%

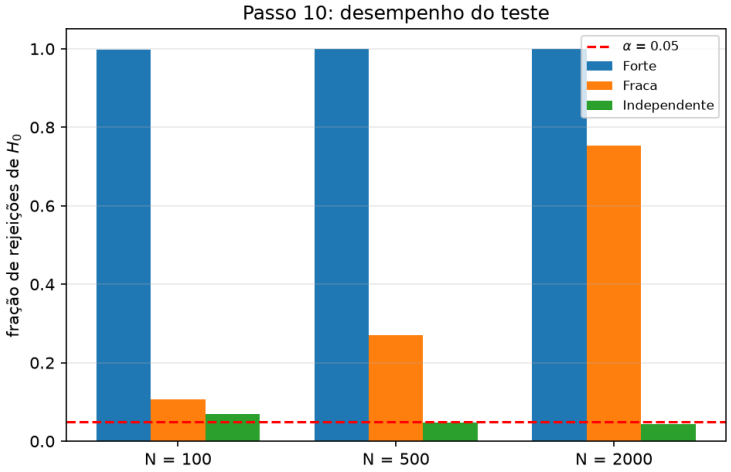


Figura 3: Passo 10: poder do teste (cenários forte e fraco) e taxa de erro tipo I (cenário independente).

1.3 As previsões teóricas se confirmaram?

- **Passo 3:** as estimativas ficaram próximas dos valores teóricos. As identidades $H(D|T) = H(D,T) - H(T)$ e $I = H(D) - H(D|T) = H(T) - H(T|D)$ valem exatamente também para as estimativas.

- **Passo 4:** o erro diminui com N. Para N pequeno, $\hat{I}$ é sistematicamente maior que o valor verdadeiro. Sob independência, $E[\hat{I}] \approx \text{g.l.}/(2N \ln 2)$, que é a média da χ^2_1 reescalada: cerca de 0,036 bit para $N = 20$, um valor que não é desprezível.

- **Passo 5:** $H(p,q) - H(p) = D(p\|q) \approx 0{,}168$ bit, confirmado também pelo custo médio medido na amostra (comprimentos ideais $-\log_2 q(d)$). A divergência não é simétrica: $D(q\|p) \approx 0{,}222 \neq D(p\|q)$.

- **Passo 7:** $\hat{H}(T_i|T_1,\ldots,T_{i-1}) \approx \hat{H}(T_i|T_{i-1}) \approx 0{,}553$ bit para $i \geq 2$. Ou seja, dado o dia anterior, os dias mais antigos não acrescentam informação (propriedade de Markov). A soma das condicionais reproduz $H(T_1,\ldots,T_8) \approx 4{,}79$ bits, contra $8H(T_1) \approx 7{,}35$ bits no esquema ingênuo.

- **Passo 8:** a economia é de $(n-1)\,I(T_i;T_{i-1}) \approx 7 \times 0{,}365 \approx 2{,}55$ bits por histórico de 8 dias. Equivalentemente, a economia é de $\approx 0{,}365$ bit por dia num histórico longo.

- **Passo 9:** as estatísticas G calculadas por nós coincidem com as da `chi2_contingency` (opção `lambda_="log-likelihood"`). Atenção: só há coincidência com `correction=False`, pois a

função aplica por padrão a correção de Yates em tabelas 2×2. As duas dependências (D–T e T_{i-1}–T_i) foram detectadas com folga.

- **Passo 10:** no cenário forte, o teste rejeita H_0 praticamente sempre. No cenário fraco ($I \approx 0{,}003$ bit), o poder cresce com N. No cenário independente, a fração de rejeições ficou próxima de $\alpha = 5\%$, que é a taxa de erro tipo I prevista. Para $N = 100$, muitas tabelas têm contagem esperada < 5, e a aproximação qui-quadrado fica menos confiável.

2 Tópico 2: Desigualdade de Processamento de Dados

2.1 O que foi feito

- **Passos 1–6:** X é um bit uniforme, passado por $k = 10$ canais BSC(p) em série, com $N = 200\,000$ mensagens. Como j BSCs em série equivalem a um BSC com $p_j = \frac{1-(1-2p)^j}{2}$, temos $I(X;Y_j) = 1 - H_b(p_j)$. Medimos também $I(X;Y_2|Y_1)$ para conferir a propriedade de Markov.
- **Passos 7–8:** o rótulo X (gato/cachorro) gera uma "imagem" $\mathbf{Z} \sim \mathcal{N}(\boldsymbol{\mu}_X, \mathbf{I}_{16})$, com $\boldsymbol{\mu}_0 = \mathbf{0}$ e $\boldsymbol{\mu}_1 = 0{,}4\,\mathbf{s}$ ($\mathbf{s}$ é um padrão de sinais ± 1). A compressão toma médias de blocos de 4 coordenadas ($16 \to 4$). A predição usa a média mais próxima no espaço comprimido.
- **Passo 9:** colapso de modelo com $K = 10$ categorias (distribuição de Zipf). Cada geração estima as frequências relativas de uma amostra de tamanho $n \in \{20, 100, 1000\}$ e gera a próxima. Fizemos 100 gerações e 200 repetições.

Como estimamos I para a imagem contínua (dúvida que tínhamos). Discretizar diretamente 16 coordenadas é inviável: com B caixas por coordenada seriam B^{16} células. Contornamos isso com a própria desigualdade de processamento. A log-razão de verossimilhança $L(\mathbf{z}) = \log \frac{p(\mathbf{z}|X=1)}{p(\mathbf{z}|X=0)}$ é uma estatística suficiente para X. Por isso $X \to \mathbf{Z} \to L$ e $X \to L \to \mathbf{Z}$ são ambas cadeias de Markov, e portanto $I(X;\mathbf{Z}) = I(X;L)$. L é unidimensional: discretizamos em 50 caixas de quantis e usamos o estimador *plug-in*. O valor teórico vem de $L|X \sim \mathcal{N}(\pm d^2/2, d^2)$, em que d^2 é a distância de Mahalanobis entre as médias, e foi calculado por integração numérica. Na imagem completa, $d^2 = 2{,}56$. Na representação comprimida, $d^2 = 0{,}8$, porque parte do padrão $\mathbf{s}$ se cancela nas médias de blocos.

2.2 Resultados

Tabela 8: Passo 4: $I(X;Y_j)$ ao longo da cadeia ($p = 0{,}1$).

Estágio j	$\hat{I}(X;Y_j)$	$I(X;Y_j)$ teórico	Diferença
0	1.0000	1.0000	-0.00000
1	0.5292	0.5310	-0.00185
2	0.3170	0.3199	-0.00288
3	0.1960	0.1984	-0.00232
4	0.1239	0.1247	-0.00072
5	0.0777	0.0789	-0.00124
6	0.0506	0.0502	+0.00044
7	0.0318	0.0320	-0.00013
8	0.0201	0.0204	-0.00032
9	0.0124	0.0130	-0.00064
10	0.0081	0.0083	-0.00021
$\hat{I}(X;Y_2\|Y_1)$	9.58×10^{-7}	0	
$\hat{I}(X;Y_1\|Y_2)$	0.2121		

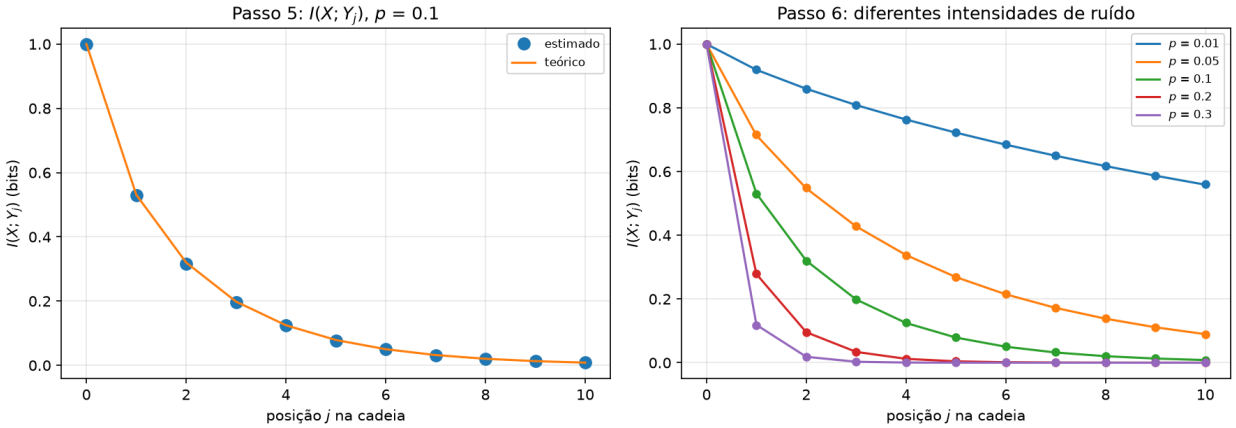


Figura 4: Passos 5–6: degradação da informação elo após elo (pontos: simulação; linhas: teoria).

Tabela 9: Passo 8: rótulo → imagem → compressão → predição.

Estágio	Dimensão	$\hat{I}(X;\cdot)$	$I(X;\cdot)$ teórico
Imagem completa	16	0.3534	0.3527
Representação comprimida	4	0.1319	0.1314
Predição final	1	0.0881	0.0878
Erro de classificação		0.3271	0.3274

Tabela 10: Passo 9: colapso de modelo.

n/geração	Geração	Mediana $D(q_g\|\|p)$	$D(p\|\|q_g) = \infty$	Categorias vivas	$H(q_g)$ média
20	0	0.3669	98%	7.40	2.518
20	9	1.5396	100%	2.92	1.209
20	49	2.5504	100%	1.15	0.111
20	99	2.5504	100%	1.01	0.005
100	0	0.0599	7%	9.93	2.809
100	9	0.5248	99%	6.97	2.288
100	49	1.4331	100%	3.04	1.216
100	99	2.0252	100%	2.06	0.694
1000	0	0.0058	0%	10.00	2.869
1000	9	0.0637	0%	9.99	2.816
1000	49	0.2911	68%	8.97	2.602
1000	99	0.5393	98%	7.34	2.330

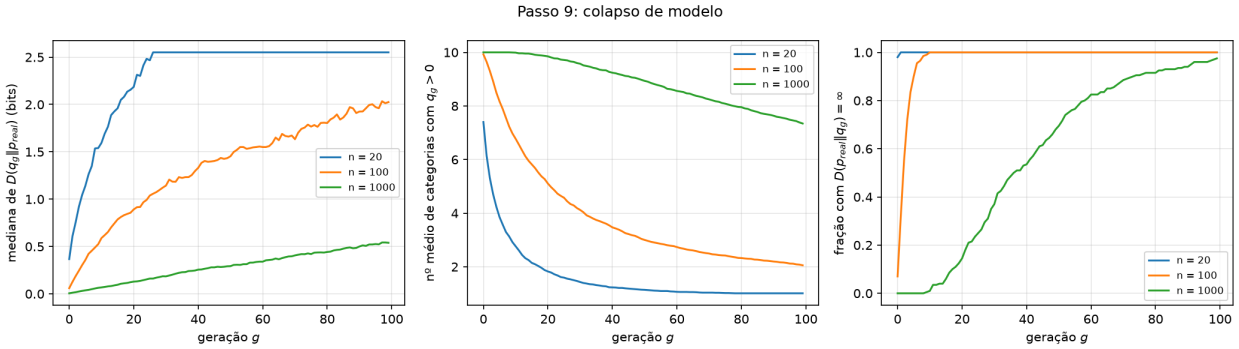


Figura 5: Passo 9: divergência, categorias sobreviventes e fração de trajetórias com $D(p_{real}\|q_g) = \infty$.

2.3 As previsões teóricas se confirmaram?

- **Passos 4–5:** $\hat{I}(X;Y_j)$ é não crescente e acompanha $1 - H_b(p_j)$: de $\approx 0{,}531$ bit ($j = 1$) para $\approx 0{,}008$ bit ($j = 10$). Medimos $\hat{I}(X;Y_2|Y_1) \approx 0$, como exige uma cadeia de Markov, enquanto $\hat{I}(X;Y_1|Y_2) > 0$.
- **Ruído de estimação:** com N pequeno (p. ex. 200) aparecem "solavancos" para cima na curva. Eles desaparecem quando N aumenta, o que confirma que são ruído de estimação (viés $\sim 1/(2N \ln 2)$), e não violações da desigualdade.
- **Passo 6:** quanto maior p, mais rápida a queda, pois $(1-2p)^j$ decai mais depressa. Com $p = 0{,}3$, a informação some em poucos elos.
- **Passo 8:** $I(X;\text{imagem}) \geq I(X;\text{comprimida}) \geq I(X;\text{predição})$, com a predição em $1 - H_b(P_e) \approx 0{,}088$ bit ($P_e \approx 0{,}327$). Nenhuma regra de decisão aplicada à representação comprimida recupera a informação perdida na compressão.
- **Passo 9:** a cada geração, categorias raras podem não ser sorteadas. Quando isso acontece, ficam com probabilidade zero para sempre, e $D(p_{real}\|q_g) = \infty$. Por isso acompanhamos também $D(q_g\|p_{real})$, o número de categorias vivas e $H(q_g)$. A diversidade (entropia) cai geração após geração, muito mais depressa com amostras pequenas ($n = 20$). A longo prazo, cada trajetória tende a se concentrar numa única categoria (estado absorvente), embora $E[q_g] = p_{real}$ em média. Esse é o mecanismo do colapso de modelo.

3 Tópico 3: Compressão, AEP e Critério de Kelly

3.1 O que foi feito

- **Modelo:** $m = 3$ resultados, com $p = (0{,}5;\ 0{,}3;\ 0{,}2)$ e $H(p) \approx 1{,}486$ bits. Usamos cotações justas $o_i = 3$ e cotações de uma casa com margem, $o = (1{,}8;\ 3{,}5;\ 5)$, para verificar que os resultados sobre divergência e informação lateral não dependem das cotações.
- **Simulação:** 1000 temporadas de 1000 partidas, geradas como uma matriz temporadas × rodadas. O patrimônio foi acompanhado em escala log (soma acumulada de $\log_2 b_X o_X$).
- **Informação lateral (Passo 9):** $P(Y = x|X = x) = 0{,}6$, com sorteio pelo vetor achatado da conjunta.
- **Crença errada (Passo 11):** $q = (0{,}65;\ 0{,}2;\ 0{,}15)$.

3.2 Resultados

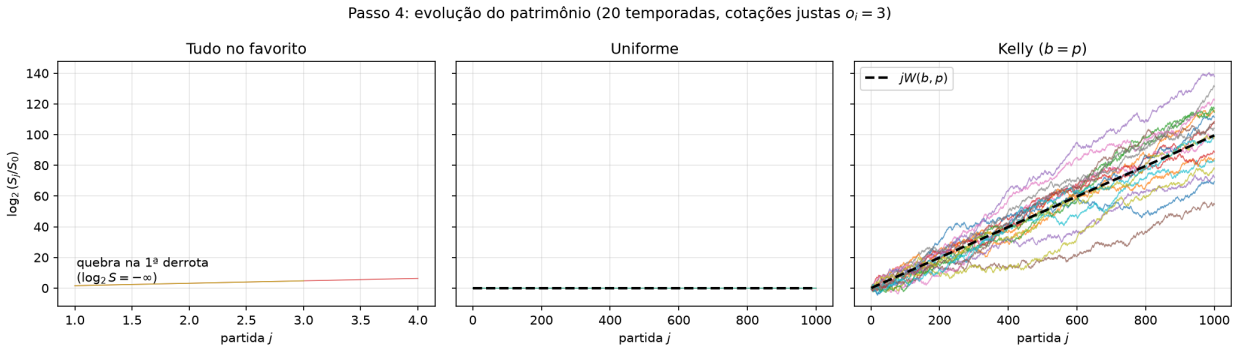


Figura 6: Passo 4: trajetórias de $\log_2(S_j/S_0)$.

Tabela 11: Passos 6–7 ($o_i = 3$, $n = 1000$, 1000 temporadas).

Estratégia	$W(b,p)$	Taxa média	Taxa mediana	$S_n < 10^{-3}S_0$	$S_n > 10^{3}S_0$	$\frac{1}{n}\log_2 E[S_n]$
Tudo no favorito	$-\infty$	$-\infty$	$-\infty$	100.0%	0.0%	0.5850
Uniforme	0.0000	0.0000	0.0000	0.0%	0.0%	0.0000
Kelly ($b = p$)	0.0995	0.0998	0.1001	0.0%	100.0%	0.1890

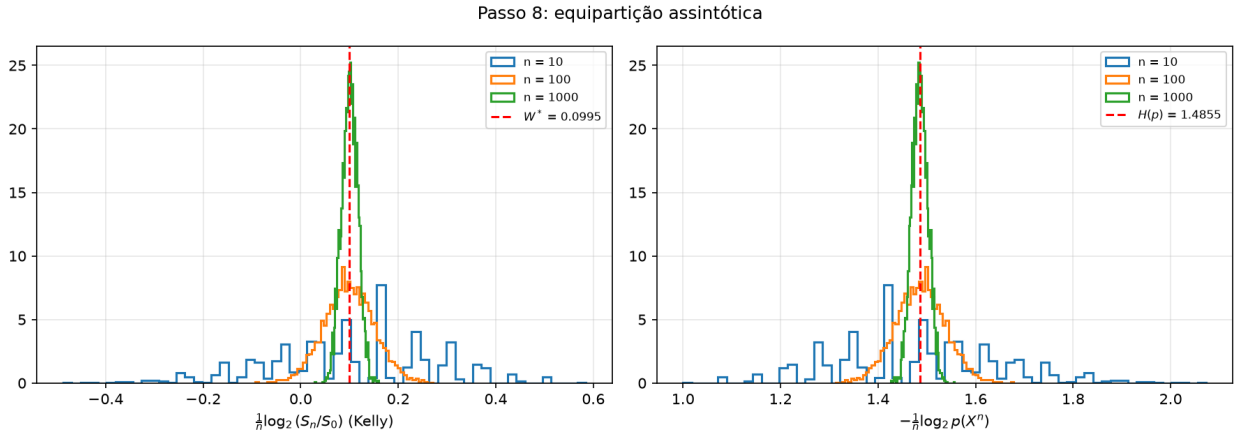


Figura 7: Passo 8: concentração da taxa de crescimento de Kelly em torno de W^* e de $-\frac{1}{n}\log_2 p(X^n)$ em torno de $H(p)$.

Tabela 12: Passo 8: concentração com n crescente.

n	Taxa Kelly (média)	dp	dp teórico	$-\frac{1}{n}\log_2 p(X^n)$ (média)	dp	Típicas ($\varepsilon = 0.05$)
10	0.1025	0.1657	0.1664	1.4824	0.1657	17.5%
100	0.0986	0.0518	0.0526	1.4863	0.0518	67.0%
1000	0.0998	0.0168	0.0166	1.4852	0.0168	99.7%

Tabela 13: Passos 9–10: ganho com informação lateral.

Cotações	W^* sem dica	W com dica	ΔW teórico	ΔW empírico	$I(X;Y)$
Justas $o_i = 3$	0.0995	0.2976	0.1981	0.1977	0.1981
Casa (1,8; 3,5; 5)	-0.0549	0.1432	0.1981	0.1977	0.1981

Tabela 14: Passo 11: custo de apostar com a distribuição errada q.

Cotações	W^*	$W(q,p)$	Perda teórica	Perda empírica	$D(p\|\|q)$
Justas $o_i = 3$	0.0995	0.0302	0.0692	0.0690	0.0692
Casa (1,8; 3,5; 5)	-0.0549	-0.1241	0.0692	0.0690	0.0692

3.3 As previsões teóricas se confirmaram?

- **Tudo no favorito:** $W = -\infty$. O apostador quebra na primeira partida em que o favorito não vence, com probabilidade $1-0{,}5^n$. Paradoxalmente, é a estratégia de maior valor *esperado* ($E[S_n] = 1{,}5^n S_0$): a média é dominada por uma trajetória rara e astronômica que nunca observamos.
- **Uniforme:** com $o_i = 3$, temos $b_i o_i = 1$ e o patrimônio fica parado ($W = 0$).
- **Kelly:** a taxa empírica concordou com $W^* = \log_2 3 - H(p) \approx 0{,}0995$ bit por aposta.
- **Passo 8 (AEP):** as distribuições de $\frac{1}{n}\log_2 S_n$ e de $-\frac{1}{n}\log_2 p(X^n)$ se concentram em torno de W^* e de $H(p)$, com desvio padrão caindo como $1/\sqrt{n}$. A fração de sequências típicas tende a 1.
- **Passo 10:** $\Delta W \approx I(X;Y) \approx 0{,}198$ bit nos dois conjuntos de cotações. Com a casa com margem, Kelly sem dica perde dinheiro ($W^* \approx -0{,}055$), mas a dica torna a aposta lucrativa ($\approx +0{,}143$).
- **Passo 11:** a perda ficou em $\approx D(p\|q) \approx 0{,}069$ bit por aposta, igual para as duas cotações. De fato, partida a partida, a diferença dos incrementos é $\log_2(p_X/q_X)$, e as cotações se cancelam.

4 Tópico 4: Capacidade de Canal e Códigos Corretores

4.1 O que foi feito

O enlace Terra–Marte foi modelado como canal binário simétrico (BSC): cada bit é invertido, independentemente, com probabilidade p. A simulação é bit a bit: sorteia-se um uniforme por bit, compara-se com p e aplica-se XOR. A capacidade é

$$C = 1 - H_b(p), \qquad H_b(p) = -p\log_2 p - (1-p)\log_2(1-p).$$

Comparamos três esquemas:

- sem código ($R = 1$);
- repetição com n_r ímpar e votação majoritária ($R = 1/n_r$);
- Hamming $(7,4)$ ($R = 4/7$), com codificação $c = dG \bmod 2$ e decodificação por síndrome $s = rH^\top \bmod 2$, cujo valor binário indica a posição do erro.

Antes da simulação, o Hamming foi testado inserindo um erro em cada uma das 7 posições das 16 mensagens possíveis: todos os erros foram corrigidos. O erro da repetição foi conferido com a cauda binomial $P(X \geq \lfloor n_r/2 \rfloor + 1)$, com $X \sim \mathrm{Bin}(n_r, p)$.

4.2 Resultados

Com $p = 0{,}1$, temos $C \approx 0{,}531$. A Tabela 15 compara os três esquemas, e a Figura 8 mostra o efeito sobre uma "foto".

Tabela 15: Passo 7 ($p = 0{,}1$, $C \approx 0{,}531$).

Método	R	Erro de bit (medido)	Erro de bit (teoria)	$R < C$?
Sem código	1.000	0.1007	0.1000	não
Repetição 3x	0.333	0.0278	0.0280	sim
Repetição 5x	0.200	0.0087	0.0086	sim
Hamming (7,4)	0.571	0.0673	–	não
Hamming, erro de *bloco*	0.571	0.1495	0.1497	não

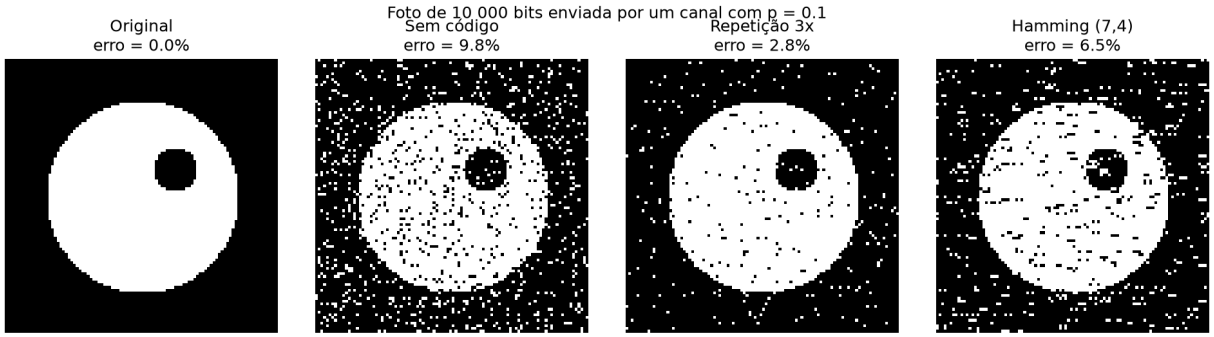


Figura 8: Imagem de 10 000 bits transmitida pelos três esquemas ($p = 0{,}1$).

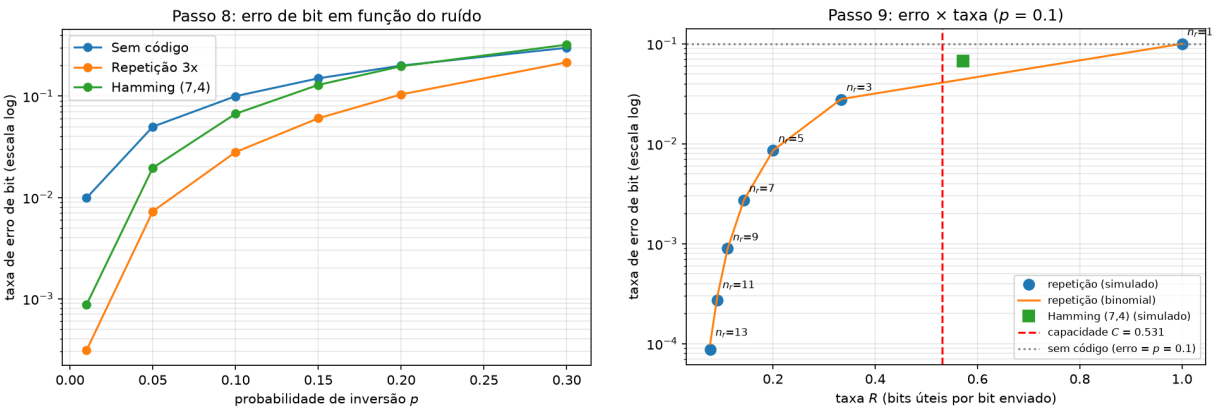


Figura 9: Esquerda: erro de bit em função de p (Passo 8). Direita: erro em função da taxa R, com a capacidade C em vermelho (Passo 9).

Tabela 16: Passo 9: repetição com n_r crescente ($p = 0{,}1$).

n_r	$R = 1/n_r$	Erro (medido)	Erro (binomial)	Nº de erros
1	1.000	0.1000	0.1000	100045
3	0.333	0.0278	0.0280	27813
5	0.200	0.0086	0.0086	8607
7	0.143	0.0027	0.0027	2735
9	0.111	8.99×10^{-4}	8.91×10^{-4}	899
11	0.091	2.71×10^{-4}	2.96×10^{-4}	271
13	0.077	8.80×10^{-5}	9.93×10^{-5}	88

Tabela 17: Passo 10: $p = 0{,}2$, $C \approx 0{,}278$.

Método	R	$R > C$?	Erro de bit	Mensagens de 100 bits sem erro
Sem código	1.000	sim	0.1994	0.0%
Hamming (7,4)	0.571	sim	0.1967	0.0%
Repetição 3x	0.333	sim	0.1042	0.0%
Repetição 5x	0.200	não	0.0578	0.2%
Repetição 9x	0.111	não	0.0196	14.2%
Repetição 15x	0.067	não	0.0043	65.1%

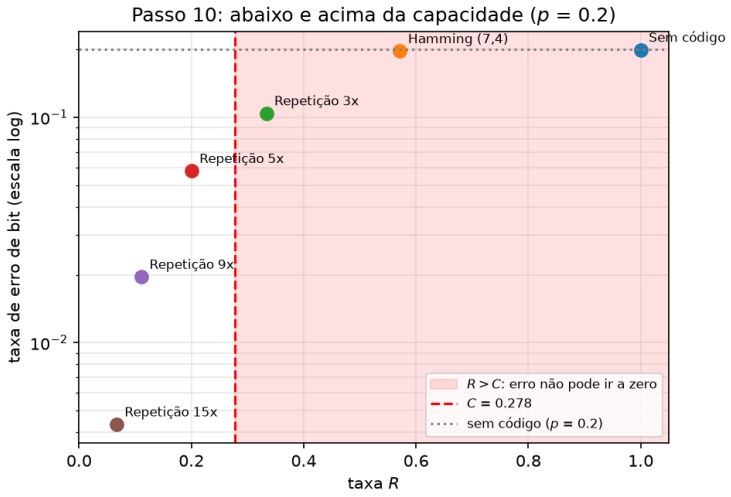


Figura 10: Passo 10: a região $R > C$ está sombreada.

4.3 As previsões teóricas se confirmaram?

- **Sem código:** o erro medido ficou próximo de p, como previsto.
- **Repetição:** o erro medido concordou com a binomial (teoria: 0,028 para $n_r = 3$ e $\approx 0{,}0086$ para $n_r = 5$ com $p = 0{,}1$).
- **Hamming:** o erro de bloco concordou com $P(\geq 2 \text{ erros em } 7) \approx 0{,}150$. Com $p = 0{,}1$, o Hamming tem $R = 0{,}571 > C = 0{,}531$, ou seja, já opera acima da capacidade.
- **Passo 8:** para p pequeno, os códigos reduzem drasticamente o erro. Conforme p cresce, a vantagem diminui, e o Hamming (que corrige só 1 erro por bloco de 7) é o primeiro a perdê-la.

- **Passo 9:** o erro da repetição cai com n_r, mas apenas porque $R = 1/n_r \to 0$. Isso *não* é a promessa de Shannon, que garante erro arbitrariamente pequeno com *taxa fixa* $R < C$, usando códigos melhores com blocos longos.
- **Passo 10:** todos os esquemas com $R > C$ mantiveram erro de bit alto, e quase nenhuma mensagem de 100 bits chegou intacta, o que é coerente com a parte inversa do teorema. Ressalva: testamos apenas os nossos códigos; o teorema vale para *qualquer* código.

Dúvidas

A principal dúvida que tivemos — como calcular $I(X;\mathbf{Z})$ quando $\mathbf{Z}$ é a "imagem" gaussiana de 16 dimensões do Tópico 2 — foi resolvida durante o trabalho com a estatística suficiente (log-razão de verossimilhança), que reduz o problema a uma dimensão; a justificativa completa está na seção do Tópico 2. Não restaram outras dúvidas.